

Índice general

1. Apéndice: Código	3
1.1. Generación de la muestra	3
1.2. Asignación de variables a localizaciones [# code:asignar_variables]	7
1.3. Depuración de la muestra	16
1.4. Análisis exploratorio	19
1.4.1. Variable objetivo	20
1.4.2. Análisis univariantes	22
1.4.3. Análisis multivariantes	31
1.5. Modelos	32
1.5.1. Partición temporal entrenamiento-validación-test	34
1.5.2. Regresión logística con penalización	34
1.5.3. Regresión logística con penalización + PCA	36
1.5.4. Árboles de decisión	37
1.5.5. Bosques aleatorios	38
1.5.6. k-Nearest Neighbours	41
1.5.7. SVM lineal	43
1.5.8. SVM radial	44
1.5.9. Comparación	45
1.5.10. Test	46
1.6. Aplicación de los modelos	48
1.6.1. Visión general del desempeño del modelo	49
1.7. Caso de interés	53
1.8. Depuración de la muestra	56
1.9. Análisis exploratorio	59
1.9.1. Variable objetivo	60
1.9.2. Análisis univariantes	62
1.9.3. Análisis multivariantes	71

1.10. Modelos	72
1.10.1. Partición temporal entrenamiento-validación-test	74
1.10.2. Regresión logística con penalización	74
1.10.3. Regresión logística con penalización + PCA	76
1.10.4. Árboles de decisión	77
1.10.5. Bosques aleatorios	78
1.10.6. k-Nearest Neighbours	82
1.10.7. SVM lineal	83
1.10.8. SVM radial	84
1.10.9. Comparación	85
1.10.10. Test	87
1.11. Aplicación de los modelos	89
1.11.1. Visión general del desempeño del modelo	89
1.12. Caso de interés	93

Capítulo 1

Apéndice: Código

1.1. Generación de la muestra

```
# Librerías -----
# Se cargan las librerías que se usarán en esta sección

library(terra) # Raster data
library(sf) # Vector data
library(mapSpain) # Polígonos de las regiones de España
library(tidyverse) # Manipulación de datos
library(lubridate) # Manipulación de fechas

# CRS de referencia -----
# Será el CRS que se use en todo el proyecto

pend <- rast("data_raw/topograficas/pendiente.tif")
crs_reference = crs(pend)
rm(pend) # Se elimina de la memoria para liberar espacio

# Polígono de Andalucía -----
Andalucia <- esp_get_ccaa(ccaa = "Andalucía") # Se obtiene el polígono
↳ de la comunidad autónoma de Andalucía
andalucia_proj <- st_transform(Andalucia,crs_reference) # Se transforma
↳ al sistema de referencia usado en el proyecto

# area_monte es el área donde se generarán las muestras negativas.

# Dado que no hay un mapa que indique claramente cuales son las zonas
↳ que se consideran "monte" en Andalucía y dado que los polígonos de
↳ incendios también cubren zonas agrícolas y urbanas (aunque menores
↳ en número que las zonas forestales), se considerará "monte" toda
↳ Andalucía, sin distinción. El sentido de esta variable es,
↳ precisamente, que pueda modificarse en futuros estudios
```

```
area_monte <- andalucia_proj

# Generación de la muestra -----

# Generación de la muestra estratificando por mes de forma que la
↪ proporción de observaciones positivas y negativas por mes (en todo
↪ el periodo) sea la misma

## Tamaño muestral -----
# Se dispone de 1089 incendios correctamente registrados entre 2002 y
↪ 2022

n_in=10 # Número de puntos a muestrear dentro de cada poligono
n_out=1089*10 # Número de muestras negativas

## Generación aleatoria de fechas para las muestras negativas ---

# Primero se leen todos los datos de todos los archivos de incendios y
↪ se almacenan en la variable incendios
incendios = NULL

for (year in 2002:2022) {
  incendios = rbind(incendios,
    ↪ st_read(paste0("./data_raw/incendios_2000-2022/incendios_",
      year, ".shp")) %>%
    select("FECHA_INIC" =
      ↪ matches("(?i)^FECHA_INIC$|^fecha_inic.$"))
}

# Se cuenta el número de incendios con fecha de inicio correcta en cada
↪ mes
incendios_mes = incendios %>%
  mutate(FECHA_INIC = ymd(FECHA_INIC), .keep="unused") %>%
  filter(!is.na(FECHA_INIC)) %>%
  filter(year(FECHA_INIC)<=2022, year(FECHA_INIC)>=2002) %>%
  st_drop_geometry() %>%
  mutate(MES = month(month(FECHA_INIC))) %>%
  count(MES)

# Fechas posibles para las muestras negativas
possible_dates = tibble (date = seq(as.Date('2002/01/01'),
  ↪ as.Date('2022/12/31'), by="day")) %>%
  mutate(MES = month(date)) %>%
  left_join(incendios_mes,
    join_by(MES))
```

```

set.seed(12345) # Se fija la semilla para que sea reproducible

# Se generan fechas aleatorias para las muestras negativas entre 2002 y
→ 2022 siguiendo con una distribución de probabilidad proporcional a
→ la cantidad de incendios observados en cada mes
dates = sample(possible_dates$date,
               n_out, replace = T,
               prob = possible_dates$n)

rm(incendios, possible_dates) # Se borran para liberar memoria

## Selección de localizaciones aleatorias -----
# Para la selección de la muestra se seguirá el siguiente
→ procedimiento:
# 1. Para las muestra positivas: Se tomarán n_in puntos aleatorios
→ dentro de cada polígono de incendio y se le asociará a cada uno de
→ ellos la fecha de inicio del incendio.
# 2. Para la muestras negativas: Se le asociará una localización
→ aleatoria dentro de area_monte a cada una de las fechas aleatorias
→ generadas dentro del periodo de estudio (dates). Se tendrá en cuenta
→ que no pueden haber muestras negativas a menos de 15km de una zona
→ en la que haya habido un incendio en una franja de 6 días alrededor
→ de la fecha de la observación (3 días antes a 3 días después).

points_in = NULL # Almacena las muestras positivas
points_out = NULL # Almacena las muestras negativas

for (year in 2002:2022) {

  cat("YEAR ", year, " : -----\n")
  cat("  Generando muestras positivas...\n")
  incendios <-
→ st_read(paste0("./data_raw/incendios_2000-2022/incendios_", year,
                  ".shp"), quiet=T) |>
  st_transform(crs = crs_reference) |>
  rename_with(.fn=tolower) |>
  mutate(fecha_inic=ymd(fecha_inic), geometry, .keep="none")

  ## Generación de puntos positivos

  for (i in 1:nrow(incendios)) {
    point_in_sfc <- st_sample(incendios[i,], size=n_in) # Se generan n_i
→ puntos dentro de cada incendio
    point_in_attr <- data.frame(fire = rep(1, n_in), date =
→ rep(incendios[i,]$fecha_inic, n_in))
    point_in <- st_sf(point_in_attr, geometry= point_in_sfc)
  }
}

```

```

    if (is.null(points_in)) {
      points_in <- point_in
    } else {
      points_in <- points_in |>
        add_row(point_in)
    }
  }
}

## Generación de puntos negativos

cat("  Generando muestras negativas...\n")
# ---> Nota: los puntos se generan en area_monte

dates_year <- dates[year(dates) == year]
locations = NULL

for (day in dates_year) {
  incendios_day = filter(incendios, fecha_inic >= day-3 &
↪ fecha_inic <= day+3)
  if (nrow(incendios_day) == 0) {
    # Si no ha habido incendios en una franja de 6 días en Andalucía
    if (is.null(locations)) {
      locations = st_sample(area_monte, size=1)
    } else {
      locations = c(locations, st_sample(area_monte, size=1))
    }
  } else {
    # Si ha habido algún incendio en una franja de 6 días en Andalucía
    ↪
    # (3 días antes a 3 días después)
    repeat {
      possible_location = st_sample(area_monte, size=1)
      # Se comprueba si está a 15km o menos de un incendio registrado
      if (!st_is_within_distance(possible_location,
                                st_union(incendios_day),
                                dist = 15000, sparse = FALSE)) {
        if (is.null(locations)) {
          locations = possible_location
          break
        } else {
          locations = c(locations, possible_location)
          break
        }
      }
    }
  }
}
}

```

```

}

points_out_attr <- data.frame(fire = rep(0,length(dates_year)),date =
↪ dates_year)

if (is.null(points_out)) {
  points_out <- st_sf(points_out_attr,geometry= locations)
} else {
  points_out <- points_out |>
    add_row(st_sf(points_out_attr,geometry= locations))
}

}

sample <- rbind(points_in,points_out) # La muestra generada

# Comprobación y corrección -----
summary(sample) # Hay una fecha de un incendio errónea
max(sample$date,na.rm=T) # "2033-08-15"

# Se eliminan las observaciones con fecha de incendio errónea que se han
↪ detectado
sample <- sample[-which(sample$date==max(sample$date,na.rm=T)),]
summary(sample) # Corregido

# Almacenamiento de resultados -----
save(sample,file=paste0("salidas_intermedias/sample_strat_",
                        Sys.Date(),".RData"))

```

1.2. Asignación de variables a localizaciones [# code:asignar_variables]

A continuación se define la función `asignar_variables` que dada una muestra de puntos en Andalucía con fechas comprendidas entre 2002 y 2022 le asocia a cada observación todos los valores de las variables consideradas en el estudio. Esta función se usará varias veces a lo largo del trabajo.

```

# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(nasapower) # Para obtener la información meteorológica
library(raster, include.only = c("rasterFromXYZ")) # Función para
↪ construir rásteres a partir de data.frames

```

```

library(tidyverse) # Manipulación de datos
library(sf) # Vector data
library(terra) # Raster data
library(mapSpain) # Polígonos de las regiones de España
library(lubridate) # Manipulación de fechas

asignar_variables = function(sample) {
  # Argumentos:
  # * sample: objeto sf con una columna de geometrías de tipo POINT
  ↪ (dentro de los límites de Andalucía) y fechas comprendidas entre
  ↪ 01/01/2002 y 31/12/2022

  crs_reference = st_crs(sample) # Se usa el sistema de referencia de
  ↪ coordenadas de la muestra
  and = esp_get_ccaa(ccaa = "Andalucía") %>%
  ↪ st_transform(st_crs(sample)) # Polígono de Andalucía

  # Variables meteorológicas -----
  cat("Asignando variables meteorológicas...\n")

  # Transformamos los datos a WGS84
  andalucia_WGS84 <- st_transform(and,crs="WGS84")

  dataset = NULL # Variable en la que se almacenará el conjunto completo

  # Se trabaja anualmente, pues la API de NASA POWER solo admite
  ↪ consultas de hasta 366 días

  for (year in sort(unique(year(sample$date)))) {

    cat("YEAR ", year, " : -----\n")

    # Los puntos de cada año
    points = filter(sample,date==year)
    points_WGS84 <- st_transform(points,crs="WGS84")

    # Consulta a la api para obtener todo los valores del año
    daily_single_ag <- get_power(
      community = "ag",
      lonlat = c(-8,35.5,-1.5,39), # Límites de Andalucía
      pars = c("T2M","GWETTOP", "RH2M","WD10M","WS10M","PRECTOTCORR"),
      dates = paste0(year,c("-01-01","-12-31")),
      temporal_api = "daily")

    # Identificador
    daily_single_ag$clim_id <- 1:nrow(daily_single_ag)
  }
}

```



```

points$clim_id = NA # Se inicializa el identificador

for (day in unique(points$date)) {

  points_day = points$date==day

  # Seleccionar un día
  clim_day <- filter(daily_single_ag,YYYYMMDD==day) |>
    dplyr::select(x = LON,y = LAT,clim_id= clim_id)

  id_rast_day = rast(rasterFromXYZ(clim_day,crs="WGS84")) # Se crea
  ↪ el raster con los identificadores

  points[points_day,]$clim_id <-
  ↪ terra::extract(id_rast_day,points_WGS84[points_day,])$clim_id # Se
  ↪ asocia a cada registro de la muestra el identificador
  ↪ correspondiente
}

# Haciendo uso del identificador se asocian todas las variables
  ↪ meteorológicas correspondientes a cada registro
points <- points |>
  left_join(select(daily_single_ag, -c(LAT,LON,DOY,YYYYMMDD)),
            by=join_by(clim_id)) |>
  select(-clim_id)

dataset = rbind(dataset,points)
}

rm(points,points_WGS84,daily_single_ag,clim_day,
  id_rast_day,points_day,day,year,andalucia_WGS84)

# Variables topográficas -----
cat("Asignando variables topográficas...\n")
elev <- rast("data_raw/topograficas/elevacion.tif")
pend <- rast("data_raw/topograficas/pendiente.tif")
orient <- rast("data_raw/topograficas/orientacion.tif")
curv <- rast("data_raw/topograficas/curvatura.tif")

# Se extraen los valores de cada una de las capas
var_topograficas <- list(elevacion = elev,pendiente = pend,
                        orientacion = orient,curvatura = curv) |>
  lapply(as.numeric) # Es necesario pasarlas a numeric para poder
                    # trabajar con ellas y extraer los valores

```

```

points_topograficas <- sapply(var_topograficas,function(x)
↪ terra::extract(x,dataset))[2,] |>
  as_tibble()

dataset <- cbind(dataset,points_topograficas)

rm(elev,pend,orient,curv,var_topograficas,points_topograficas)

# Variables antropogénicas -----
cat("Asignando variables antropogénicas...\n")

## Para optimizar el cálculo evitando que se repitan cálculos si hay
↪ puntos repetidos:!!
dataset_geoms <- dataset %>%
  group_by(geometry) %>%
  group_keys() %>%
  st_sf(crs = st_crs(dataset))

### Carreteras: ----
carreteras <-
↪ read_sf("data_raw/antropologicas/RedCarreteras/09_14_RedCarreteras.shp")
↪ |>
  st_union()

dataset_geoms$dist_carretera <- st_distance(dataset_geoms,carreteras)
↪ |>
  as.numeric()      # metres

rm(carreteras)

### Poblaciones: ----
poblaciones <-
↪ read_sf("data_raw/antropologicas/Poblaciones/07_01_Poblaciones.shp")
↪ |>
  st_union()

dataset_geoms$dist_poblacion <- st_distance(dataset_geoms,poblaciones)
↪ |>
  as.numeric()      # metres

rm(poblaciones)

### Linea Eléctrica: ----
linea_electrica <-
↪ read_sf("data_raw/antropologicas/LineaElectrica/10_14_LineaElectrica.shp")
↪ |>

```

```

    st_union()

dataset_geoms$dist_electr <- st_distance(dataset_geoms,linea_electrica)
↪ |>
    as.numeric() # metres

rm(linea_electrica)

### Ferrocarril: ----
ferrocarril <-
↪ read_sf("data_raw/antropologicas/Ferrocarril/09_21_Ferrocarril.shp")
↪ |>
    st_union()
dataset_geoms$dist_ferrocarril <-
↪ st_distance(dataset_geoms,ferrocarril) |>
    as.numeric()

rm(ferrocarril)

### Camino / Via: ----
camino <- read_sf("data_raw/antropologicas/Camino/09_19_Camino.shp")
viapec <-
↪ read_sf("data_raw/antropologicas/Camino/09_22_ViasPecuarias.shp")

camino_viapec <- c(st_geometry(camino),st_geometry(viapec))
rm(camino,viapec)

camino_viapec <- st_union(camino_viapec)

dataset_geoms$dist_camino <- st_distance(dataset_geoms,camino_viapec)
↪ |>
    as.numeric()

rm(camino_viapec)

### Sendero / Vía Verde / CarrilBici: ----
viaverde <-
↪ read_sf("data_raw/antropologicas/Sendero_ViaVerde/09_24_ViaVerde.shp")
↪
sendero <-
↪ read_sf("data_raw/antropologicas/sendero_ViaVerde/09_20_Sendero.shp")
↪
carrilbic <-
↪ read_sf("data_raw/antropologicas/sendero_ViaVerde/09_23_CarrilBici.shp")

sendero_viaverde_carrilbici <-
↪ c(st_geometry(viaverde),st_geometry(sendero),st_geometry(carrilbic))
↪ |>

```

```

    st_union()

dataset_geoms$dist_sendero <-
↪  st_distance(dataset_geoms,sendero_viaverde_carrilbici) |>
    as.numeric()

rm(sendero,sendero_viaverde_carrilbici,viaverde,carrilbic)

### ENP: ----
enp1 <-
↪  read_sf("data_raw/antropologicas/ENP/11_07_Enp_FiguraProteccion.shp"
↪  )
enp2 <-
↪  read_sf("data_raw/antropologicas/ENP/11_07_Enp_RegimenProteccion.shp")

enp <- c(st_geometry(enp1),st_geometry(enp2)) |> st_union()
enp_sf <- st_sf(enp)

# Se rasteriza para aumentar la eficiencia computacional
enp_rast <- rasterize(enp_sf,
                      rast("data_raw/topograficas/pendiente.tif"), #
                      ↪  Modelo
                      background = 0)
dataset_geoms$enp= terra::extract(enp_rast,dataset_geoms)[,2]

rm(enp,enp1,enp2,enp_sf,enp_rast)

### Uso Suelo: ----
# Inicialmente se ha rasterizado para aumentar la eficiencia
↪  computacional
# UsoSuelo <-
↪  read_sf("data_raw/antropologicas/UsoSuelo/06_01_UsoSuelo.shp")
# UsoSuelo_rast <- rasterize(UsoSuelo,
#
↪  rast("data_raw/topograficas/pendiente.tif"), # Modelo
#
↪  field="cod_uso")

UsoSuelo_rast <- rast("data_cleaning/uso_suelo_rast.tiff")

dataset_geoms$uso_suelo =
↪  terra::extract(UsoSuelo_rast,dataset_geoms)[,2]

# Hidrográficas -----
cat("Asignando variables hidrográficas...\n")

### Distancia a ríos: ----
rios <- read_sf("data_raw/hidrograficas/Rios_Espana.shp") |>

```

```

st_transform(st_crs(dataset)) |>
st_crop(xmin = 100394.4, # Esto se hace solo para no tener que
  ↳ considerar todo el file y que sea más eficiente
  ↳ computacionalmente
      ymin = 3976888.6,
      xmax = 690000.8,
      ymax = 4350000.0) |>
st_union()

dataset_geoms$dist_rios <- st_distance(dataset_geoms,rios) |>
as.numeric() # metres

rm(rios)

## Se vuelven a desagrupar los registros y se le asigna a cada
  ↳ registro los valores correspondientes calculados!!
dataset <- dataset %>%
  st_join(dataset_geoms,left = TRUE) # Es un left join espacial

# Demográficas -----
cat("Asignando variables demográficas...\n")

### Población y densidad de población: ----

poblacion <-
↳ read_csv2("data_raw/antropologicas/Población/poblacion_municipios.txt",
            locale=locale(decimal_mark = ","),
            col_select = 1:5,col_types = "ccifn") |>
mutate(Valor=as.integer(round(Valor))) # La población debe ser un
  ↳ entero

area_municipios <-
↳ read_csv2("data_raw/antropologicas/Población/extension_municipal.txt",
            locale=locale(decimal_mark = ","),
            col_select = 1:6, col_types = "fffffn")

area_municipios <- area_municipios %>%
  filter(!is.na(CODIGO_INE3)) %>%
  select(CODIGO_INE3,Valor) %>%
  rename("Area" = "Valor")

# Se calcula la densidad de población anual como el cociente del
  ↳ número de habitantes entre la extensión del municipio
dens_poblacion <- poblacion %>%
  select(-Medida) %>%
  rename("Poblacion" = "Valor",

```

```

    "Municipio" = "Lugar de residencia") %>%
left_join(area_municipios,
           join_by("CODIGO_INE3")) %>%
mutate(dens_poblacion = Poblacion/Area) %>%
select(-Area)

municipios <- esp_get_munic(epsg = 4258,region = "Andalucía") |>
  st_transform(crs_reference)

# Se asocia cada observacion su código de municipio correspondiente

num_mun = st_intersects(dataset,municipios)

# Se eliminan las observaciones que no están en ningún municipio
if (any(sapply(num_mun,function(x) length(x) == 0))) {
  cat("Eliminamos las
    ↪ observaciones:\n",which(sapply(num_mun,function(x) length(x) ==
    ↪ 0)))
  dataset = dataset[-which(sapply(num_mun,function(x) length(x) ==
↪ 0)),]
}

dataset$cod_municipio <-
↪ municipios[unlist(st_intersects(dataset,municipios)),]$LAU_CODE

dataset <- dataset |>
  left_join(dens_poblacion,
            join_by(cod_municipio==CODIGO_INE3,YEAR==Anual)) |>
  rename("municipio" = "Municipio",
         "poblacion" = "Poblacion")

# Vegetación -----
cat("Asignando variables de vegetación...\n")

### NDVI ----
dataset$NDVI = NA

for (YEAR in 2002:2022) {
  for (MONTH in 1:12) {
    MM = str_pad(MONTH,2,"left",pad = "0")
    YY = substr(as.character(YEAR),3,4)
    # if (as.numeric(YY)<=01) {
    #   ruta <-
    ↪ paste0("data_raw/vegetacion/",YEAR,"NOAAVHMEDMNDVI/InfGeografica/InfRaster
    # } else
    if (as.numeric(YY)<=06) {
      ruta <-
↪ paste0("data_raw/vegetacion/",YEAR,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIFF/TI

```

```

    } else if (as.numeric(YEAR)<=11) {
      ruta <-
→ paste0("data_raw/vegetacion/",YEAR,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIF/TE
    } else if (as.numeric(YEAR)<=21) {
      ruta <-
→ paste0("data_raw/vegetacion/",YEAR,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIFF/t
    }else {
      ruta <-
→ paste0("data_raw/vegetacion/",YEAR,"TERMODMEDMNDVI/InfGeografica/InfRaster/COG/te
    }

    if (file.exists(ruta)) {
      cat(YEAR,MONTH,"\\n")
      # Observaciones en ese mes y año
      isMY = dataset$YEAR==YEAR & dataset$MM==MONTH
      if (any(isMY)) {
        NDVI_rast = as.numeric(rast(ruta))
        if (MONTH==4 & YEAR==2011){
          # Ese archivo viene defectuoso y se le asigna el CRS de los
          → otros archivos del mismo año (todos los demás del año
          → tienen el mismo)
          crs(NDVI_rast) = crs(rast(
            → "data_raw/vegetacion/2011TERMODMEDMNDVI/InfGeografica/InfRaster/TIF/
          )
          dataset[isMY,]$NDVI =
→ terra::extract(NDVI_rast,dataset[isMY,])[,2]
        }
      } else
        cat("No existe: ",YEAR,"-",MONTH,"\\n")
    }
  }

  # Factores -----
  # Codificación de las variables categóricas como factores:

  dataset <- dataset |>
    mutate(enp = as.factor(enp),
           orientacion = cut(orientacion,
                             breaks =
→ c(-Inf,-1,22.5,67.5,112.5,157.5,202.5,247.5,292.5,337.5,382.5,427.5,472.5,517.5,562.5,607.5,652.5,697.5,742.5,787.5,832.5,877.5,922.5,967.5,1012.5,1057.5,1102.5,1147.5,1192.5,1237.5,1282.5,1327.5,1372.5,1417.5,1462.5,1507.5,1552.5,1597.5,1642.5,1687.5,1732.5,1777.5,1822.5,1867.5,1912.5,1957.5,2002.5,2047.5,2092.5,2137.5,2182.5,2227.5,2272.5,2317.5,2362.5,2407.5,2452.5,2497.5,2542.5,2587.5,2632.5,2677.5,2722.5,2767.5,2812.5,2857.5,2902.5,2947.5,2992.5,3037.5,3082.5,3127.5,3172.5,3217.5,3262.5,3307.5,3352.5,3397.5,3442.5,3487.5,3532.5,3577.5,3622.5,3667.5,3712.5,3757.5,3802.5,3847.5,3892.5,3937.5,3982.5,4027.5,4072.5,4117.5,4162.5,4207.5,4252.5,4297.5,4342.5,4387.5,4432.5,4477.5,4522.5,4567.5,4612.5,4657.5,4702.5,4747.5,4792.5,4837.5,4882.5,4927.5,4972.5,5017.5,5062.5,5107.5,5152.5,5197.5,5242.5,5287.5,5332.5,5377.5,5422.5,5467.5,5512.5,5557.5,5602.5,5647.5,5692.5,5737.5,5782.5,5827.5,5872.5,5917.5,5962.5,6007.5,6052.5,6097.5,6142.5,6187.5,6232.5,6277.5,6322.5,6367.5,6412.5,6457.5,6502.5,6547.5,6592.5,6637.5,6682.5,6727.5,6772.5,6817.5,6862.5,6907.5,6952.5,6997.5,7042.5,7087.5,7132.5,7177.5,7222.5,7267.5,7312.5,7357.5,7402.5,7447.5,7492.5,7537.5,7582.5,7627.5,7672.5,7717.5,7762.5,7807.5,7852.5,7897.5,7942.5,7987.5,8032.5,8077.5,8122.5,8167.5,8212.5,8257.5,8302.5,8347.5,8392.5,8437.5,8482.5,8527.5,8572.5,8617.5,8662.5,8707.5,8752.5,8797.5,8842.5,8887.5,8932.5,8977.5,9022.5,9067.5,9112.5,9157.5,9202.5,9247.5,9292.5,9337.5,9382.5,9427.5,9472.5,9517.5,9562.5,9607.5,9652.5,9697.5,9742.5,9787.5,9832.5,9877.5,9922.5,9967.5,10012.5,10057.5,10102.5,10147.5,10192.5,10237.5,10282.5,10327.5,10372.5,10417.5,10462.5,10507.5,10552.5,10597.5,10642.5,10687.5,10732.5,10777.5,10822.5,10867.5,10912.5,10957.5,11002.5,11047.5,11092.5,11137.5,11182.5,11227.5,11272.5,11317.5,11362.5,11407.5,11452.5,11497.5,11542.5,11587.5,11632.5,11677.5,11722.5,11767.5,11812.5,11857.5,11902.5,11947.5,11992.5,12037.5,12082.5,12127.5,12172.5,12217.5,12262.5,12307.5,12352.5,12397.5,12442.5,12487.5,12532.5,12577.5,12622.5,12667.5,12712.5,12757.5,12802.5,12847.5,12892.5,12937.5,12982.5,13027.5,13072.5,13117.5,13162.5,13207.5,13252.5,13297.5,13342.5,13387.5,13432.5,13477.5,13522.5,13567.5,13612.5,13657.5,13702.5,13747.5,13792.5,13837.5,13882.5,13927.5,13972.5,14017.5,14062.5,14107.5,14152.5,14197.5,14242.5,14287.5,14332.5,14377.5,14422.5,14467.5,14512.5,14557.5,14602.5,14647.5,14692.5,14737.5,14782.5,14827.5,14872.5,14917.5,14962.5,15007.5,15052.5,15097.5,15142.5,15187.5,15232.5,15277.5,15322.5,15367.5,15412.5,15457.5,15502.5,15547.5,15592.5,15637.5,15682.5,15727.5,15772.5,15817.5,15862.5,15907.5,15952.5,16002.5,16047.5,16092.5,16137.5,16182.5,16227.5,16272.5,16317.5,16362.5,16407.5,16452.5,16497.5,16542.5,16587.5,16632.5,16677.5,16722.5,16767.5,16812.5,16857.5,16902.5,16947.5,16992.5,17037.5,17082.5,17127.5,17172.5,17217.5,17262.5,17307.5,17352.5,17397.5,17442.5,17487.5,17532.5,17577.5,17622.5,17667.5,17712.5,17757.5,17802.5,17847.5,17892.5,17937.5,17982.5,18027.5,18072.5,18117.5,18162.5,18207.5,18252.5,18297.5,18342.5,18387.5,18432.5,18477.5,18522.5,18567.5,18612.5,18657.5,18702.5,18747.5,18792.5,18837.5,18882.5,18927.5,18972.5,19017.5,19062.5,19107.5,19152.5,19197.5,19242.5,19287.5,19332.5,19377.5,19422.5,19467.5,19512.5,19557.5,19602.5,19647.5,19692.5,19737.5,19782.5,19827.5,19872.5,19917.5,19962.5,20007.5,20052.5,20097.5,20142.5,20187.5,20232.5,20277.5,20322.5,20367.5,20412.5,20457.5,20502.5,20547.5,20592.5,20637.5,20682.5,20727.5,20772.5,20817.5,20862.5,20907.5,20952.5,21002.5,21047.5,21092.5,21137.5,21182.5,21227.5,21272.5,21317.5,21362.5,21407.5,21452.5,21497.5,21542.5,21587.5,21632.5,21677.5,21722.5,21767.5,21812.5,21857.5,21902.5,21947.5,21992.5,22037.5,22082.5,22127.5,22172.5,22217.5,22262.5,22307.5,22352.5,22397.5,22442.5,22487.5,22532.5,22577.5,22622.5,22667.5,22712.5,22757.5,22802.5,22847.5,22892.5,22937.5,22982.5,23027.5,23072.5,23117.5,23162.5,23207.5,23252.5,23297.5,23342.5,23387.5,23432.5,23477.5,23522.5,23567.5,23612.5,23657.5,23702.5,23747.5,23792.5,23837.5,23882.5,23927.5,23972.5,24017.5,24062.5,24107.5,24152.5,24197.5,24242.5,24287.5,24332.5,24377.5,24422.5,24467.5,24512.5,24557.5,24602.5,24647.5,24692.5,24737.5,24782.5,24827.5,24872.5,24917.5,24962.5,25007.5,25052.5,25097.5,25142.5,25187.5,25232.5,25277.5,25322.5,25367.5,25412.5,25457.5,25502.5,25547.5,25592.5,25637.5,25682.5,25727.5,25772.5,25817.5,25862.5,25907.5,25952.5,26002.5,26047.5,26092.5,26137.5,26182.5,26227.5,26272.5,26317.5,26362.5,26407.5,26452.5,26497.5,26542.5,26587.5,26632.5,26677.5,26722.5,26767.5,26812.5,26857.5,26902.5,26947.5,26992.5,27037.5,27082.5,27127.5,27172.5,27217.5,27262.5,27307.5,27352.5,27397.5,27442.5,27487.5,27532.5,27577.5,27622.5,27667.5,27712.5,27757.5,27802.5,27847.5,27892.5,27937.5,27982.5,28027.5,28072.5,28117.5,28162.5,28207.5,28252.5,28297.5,28342.5,28387.5,28432.5,28477.5,28522.5,28567.5,28612.5,28657.5,28702.5,28747.5,28792.5,28837.5,28882.5,28927.5,28972.5,29017.5,29062.5,29107.5,29152.5,29197.5,29242.5,29287.5,29332.5,29377.5,29422.5,29467.5,29512.5,29557.5,29602.5,29647.5,29692.5,29737.5,29782.5,29827.5,29872.5,29917.5,29962.5,30007.5,30052.5,30097.5,30142.5,30187.5,30232.5,30277.5,30322.5,30367.5,30412.5,30457.5,30502.5,30547.5,30592.5,30637.5,30682.5,30727.5,30772.5,30817.5,30862.5,30907.5,30952.5,31002.5,31047.5,31092.5,31137.5,31182.5,31227.5,31272.5,31317.5,31362.5,31407.5,31452.5,31497.5,31542.5,31587.5,31632.5,31677.5,31722.5,31767.5,31812.5,31857.5,31902.5,31947.5,31992.5,32037.5,32082.5,32127.5,32172.5,32217.5,32262.5,32307.5,32352.5,32397.5,32442.5,32487.5,32532.5,32577.5,32622.5,32667.5,32712.5,32757.5,32802.5,32847.5,32892.5,32937.5,32982.5,33027.5,33072.5,33117.5,33162.5,33207.5,33252.5,33297.5,33342.5,33387.5,33432.5,33477.5,33522.5,33567.5,33612.5,33657.5,33702.5,33747.5,33792.5,33837.5,33882.5,33927.5,33972.5,34017.5,34062.5,34107.5,34152.5,34197.5,34242.5,34287.5,34332.5,34377.5,34422.5,34467.5,34512.5,34557.5,34602.5,34647.5,34692.5,34737.5,34782.5,34827.5,34872.5,34917.5,34962.5,35007.5,35052.5,35097.5,35142.5,35187.5,35232.5,35277.5,35322.5,35367.5,35412.5,35457.5,35502.5,35547.5,35592.5,35637.5,35682.5,35727.5,35772.5,35817.5,35862.5,35907.5,35952.5,36002.5,36047.5,36092.5,36137.5,36182.5,36227.5,36272.5,36317.5,36362.5,36407.5,36452.5,36497.5,36542.5,36587.5,36632.5,36677.5,36722.5,36767.5,36812.5,36857.5,36902.5,36947.5,36992.5,37037.5,37082.5,37127.5,37172.5,37217.5,37262.5,37307.5,37352.5,37397.5,37442.5,37487.5,37532.5,37577.5,37622.5,37667.5,37712.5,37757.5,37802.5,37847.5,37892.5,37937.5,37982.5,38027.5,38072.5,38117.5,38162.5,38207.5,38252.5,38297.5,38342.5,38387.5,38432.5,38477.5,38522.5,38567.5,38612.5,38657.5,38702.5,38747.5,38792.5,38837.5,38882.5,38927.5,38972.5,39017.5,39062.5,39107.5,39152.5,39197.5,39242.5,39287.5,39332.5,39377.5,39422.5,39467.5,39512.5,39557.5,39602.5,39647.5,39692.5,39737.5,39782.5,39827.5,39872.5,39917.5,39962.5,40007.5,40052.5,40097.5,40142.5,40187.5,40232.5,40277.5,40322.5,40367.5,40412.5,40457.5,40502.5,40547.5,40592.5,40637.5,40682.5,40727.5,40772.5,40817.5,40862.5,40907.5,40952.5,41002.5,41047.5,41092.5,41137.5,41182.5,41227.5,41272.5,41317.5,41362.5,41407.5,41452.5,41497.5,41542.5,41587.5,41632.5,41677.5,41722.5,41767.5,41812.5,41857.5,41902.5,41947.5,41992.5,42037.5,42082.5,42127.5,42172.5,42217.5,42262.5,42307.5,42352.5,42397.5,42442.5,42487.5,42532.5,42577.5,42622.5,42667.5,42712.5,42757.5,42802.5,42847.5,42892.5,42937.5,42982.5,43027.5,43072.5,43117.5,43162.5,43207.5,43252.5,43297.5,43342.5,43387.5,43432.5,43477.5,43522.5,43567.5,43612.5,43657.5,43702.5,43747.5,43792.5,43837.5,43882.5,43927.5,43972.5,44017.5,44062.5,44107.5,44152.5,44197.5,44242.5,44287.5,44332.5,44377.5,44422.5,44467.5,44512.5,44557.5,44602.5,44647.5,44692.5,44737.5,44782.5,44827.5,44872.5,44917.5,44962.5,45007.5,45052.5,45097.5,45142.5,45187.5,45232.5,45277.5,45322.5,45367.5,45412.5,45457.5,45502.5,45547.5,45592.5,45637.5,45682.5,45727.5,45772.5,45817.5,45862.5,45907.5,45952.5,46002.5,46047.5,46092.5,46137.5,46182.5,46227.5,46272.5,46317.5,46362.5,46407.5,46452.5,46497.5,46542.5,46587.5,46632.5,46677.5,46722.5,46767.5,46812.5,46857.5,46902.5,46947.5,46992.5,47037.5,47082.5,47127.5,47172.5,47217.5,47262.5,47307.5,47352.5,47397.5,47442.5,47487.5,47532.5,47577.5,47622.5,47667.5,47712.5,47757.5,47802.5,47847.5,47892.5,47937.5,47982.5,48027.5,48072.5,48117.5,48162.5,48207.5,48252.5,48297.5,48342.5,48387.5,48432.5,48477.5,48522.5,48567.5,48612.5,48657.5,48702.5,48747.5,48792.5,48837.5,48882.5,48927.5,48972.5,49017.5,49062.5,49107.5,49152.5,49197.5,49242.5,49287.5,49332.5,49377.5,49422.5,49467.5,49512.5,49557.5,49602.5,49647.5,49692.5,49737.5,49782.5,49827.5,49872.5,49917.5,49962.5,50007.5,50052.5,50097.5,50142.5,50187.5,50232.5,50277.5,50322.5,50367.5,50412.5,50457.5,50502.5,50547.5,50592.5,50637.5,50682.5,50727.5,50772.5,50817.5,50862.5,50907.5,50952.5,51002.5,51047.5,51092.5,51137.5,51182.5,51227.5,51272.5,51317.5,51362.5,51407.5,51452.5,51497.5,51542.5,51587.5,51632.5,51677.5,51722.5,51767.5,51812.5,51857.5,51902.5,51947.5,51992.5,52037.5,52082.5,52127.5,52172.5,52217.5,52262.5,52307.5,52352.5,52397.5,52442.5,52487.5,52532.5,52577.5,52622.5,52667.5,52712.5,52757.5,52802.5,52847.5,52892.5,52937.5,52982.5,53027.5,53072.5,53117.5,53162.5,53207.5,53252.5,53297.5,53342.5,53387.5,53432.5,53477.5,53522.5,53567.5,53612.5,53657.5,53702.5,53747.5,53792.5,53837.5,53882.5,53927.5,53972.5,54017.5,54062.5,54107.5,54152.5,54197.5,54242.5,54287.5,54332.5,54377.5,54422.5,54467.5,54512.5,54557.5,54602.5,54647.5,54692.5,54737.5,54782.5,54827.5,54872.5,54917.5,54962.5,55007.5,55052.5,55097.5,55142.5,55187.5,55232.5,55277.5,55322.5,55367.5,55412.5,55457.5,55502.5,55547.5,55592.5,55637.5,55682.5,55727.5,55772.5,55817.5,55862.5,55907.5,55952.5,56002.5,56047.5,56092.5,56137.5,56182.5,56227.5,56272.5,56317.5,56362.5,56407.5,56452.5,56497.5,56542.5,56587.5,56632.5,56677.5,56722.5,56767.5,56812.5,56857.5,56902.5,56947.5,56992.5,57037.5,57082.5,57127.5,57172.5,57217.5,57262.5,57307.5,57352.5,57397.5,57442.5,57487.5,57532.5,57577.5,57622.5,57667.5,57712.5,57757.5,57802.5,57847.5,57892.5,57937.5,57982.5,58027.5,58072.5,58117.5,58162.5,58207.5,58252.5,58297.5,58342.5,58387.5,58432.5,58477.5,58522.5,58567.5,58612.5,58657.5,58702.5,58747.5,58792.5,58837.5,58882.5,58927.5,58972.5,59017.5,59062.5,59107.5,59152.5,59197.5,59242.5,59287.5,59332.5,59377.5,59422.5,59467.5,59512.5,59557.5,59602.5,59647.5,59692.5,59737.5,59782.5,59827.5,59872.5,59917.5,59962.5,60007.5,60052.5,60097.5,60142.5,60187.5,60232.5,60277.5,60322.5,60367.5,60412.5,60457.5,60502.5,60547.5,60592.5,60637.5,60682.5,60727.5,60772.5,60817.5,60862.5,60907.5,60952.5,61002.5,61047.5,61092.5,61137.5,61182.5,61227.5,61272.5,61317.5,61362.5,61407.5,61452.5,61497.5,61542.5,61587.5,61632.5,61677.5,61722.5,61767.5,61812.5,61857.5,61902.5,61947.5,61992.5,62037.5,62082.5,62127.5,62172.5,62217.5,62262.5,62307.5,62352.5,62397.5,62442.5,62487.5,62532.5,62577.5,62622.5,62667.5,62712.5,62757.5,62802.5,62847.5,62892.5,62937.5,62982.5,63027.5,63072.5,63117.5,63162.5,63207.5,63252.5,63297.5,63342.5,63387.5,63432.5,63477.5,63522.5,63567.5,63612.5,63657.5,63702.5,63747.5,63792.5,63837.5,63882.5,63927.5,63972.5,64017.5,64062.5,64107.5,64152.5,64197.5,64242.5,64287.5,64332.5,64377.5,64422.5,64467.5,64512.5,64557.5,64602.5,64647.5,64692.5,64737.5,64782.5,64827.5,64872.5,64917.5,64962.5,65007.5,65052.5,65097.5,65142.5,65187.5,65232.5,65277.5,65322.5,65367.5,65412.5,65457.5,65502.5,65547.5,65592.5,65637.5,65682.5,65727.5,65772.5,65817.5,65862.5,65907.5,65952.5,66002.5,66047.5,66092.5,66137.5,66182.5,66227.5,66272.5,66317.5,66362.5,66407.5,66452.5,66497.5,66542.5,66587.5,66632.5,66677.5,66722.5,66767.5,66812.5,66857.5,66902.5,66947.5,66992.5,67037.5,67082.5,67127.5,67172.5,67217.5,67262.5,67307.5,67352.5,67397.5,67442.5,67487.5,67532.5,67577.5,67622.5,67667.5,67712.5,67757.5,67802.5,67847.5,67892.5,67937.5,67982.5,68027.5,
```

```

        labels =
          ↪ c("N","NE","E","SE","S","SW","W","NW","N")),
      uso_suelo = uso_suelo |> as.character() |> str_sub(0,2) |>
        ↪ as.factor()
      ) %>%
    select(-c(YEAR,MM,DD))

  return(dataset)
}

```

Se usa la función definida para asignar las variables explicativas a la muestra generada:

```

# Se carga la muestra generada en el paso anterior:
load("salidas_intermedias/sample_strat_2024-04-26.RData")

# Se eliminan las observaciones que no tienen fecha pues se pueden usar
↪ para el estudio
sample <- na.omit(sample)

# Se aplica la función a la muestra
dataset <- asignar_variables(sample)

# Se almacenan los resultados
save(dataset,
      file = paste0("salidas_intermedias/dataset_strat_completo",
                    Sys.Date(), ".RData"))

```

1.3. Depuración de la muestra

En la propia función usada para generar la muestra ya se ajustaron los tipos de las variables y se codificaron adecuadamente las variables *WD10M* y *orientacion*. A continuación se estudian los casos faltantes y finalmente se decide eliminarlos.

```

# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos
library(sf) # Vector data
library(terra) # Raster data
library(mapSpain) # Polígonos de regiones de España
library(magrittr) # Operador %<>%
library(skimr) # Resumen de datos

# Carga de los datos -----
# Se carga la muestra con todas las variables construida anteriormente
load("salidas_intermedias/dataset_strat_completo2024-04-26.RData")

```



```

# Codificación variable fire: -----
datos <- dataset |>
  mutate(fire = as.factor(fire))

# Análisis de valores perdidos: -----
datos %>% skim()
dataset %>% apply(1,anyNA) %>% sum() # 200 registros con valores
  ↳ perdidos

# Se observan:
#   8 nas en uso_suelo
#   32 nas en pendiente
#   36 nas en orientacion
#   32 nas en curvatura
#   85 nas en doblacion y en dist_poblacion
#   85 nas en NDVI

# Valores perdidos en variables topográficas -----
Andalucia <- esp_get_ccaa(ccaa = "Andalucía") # Se carga el mapa de
  ↳ Andalucía
andalucia_proj <- st_transform(Andalucia,st_crs(dataset)) # Se proyecta
  ↳ al sistema de referencia de los datos

# Mapa de valores perdidos en variables topográficas:
plot(st_geometry(andalucia_proj),reset=F)
datos |>
  filter(is.na(pendiente) | is.na(orientacion) | is.na(curvatura)) |>
  st_geometry() |>
  plot(pch=16,col="red",add=T) # Se encuentran en los límites de
  ↳ Andalucía

datos |>
  st_drop_geometry() |>
  filter(is.na(pendiente) | is.na(orientacion) | is.na(curvatura)) |>
  count() #53 registros con algún valor perdido entre las variables
  ↳ topográficas

# Valores perdidos en variables demográficas -----
# Se observa que los valores perdidos se deben a que los datos no están
  ↳ disponibles en el conjunto de datos disponible en el INE
datos |>
  st_drop_geometry() |>
  filter(is.na(poblacion)) |>
  mutate(Año = year(date)) |>

```

```

select(Año,municipio,cod_municipio)

# Ejemplo:
pob =
  ↪ read_csv2("data_raw/antropologicas/Población/poblacion_municipios.txt")[,c(1:5)]
  ↪
pob |> filter(CODIGO_INE3 == "18077") # Datos no disponibles

datos |>
  st_drop_geometry() |>
  filter(is.na(poblacion)) |>
  count() # 85 registros con valores perdidos en las variables
  ↪ demográficas

# Valores perdidos en uso_suelo -----
dataset |> filter(is.na(uso_suelo)) %>% count() # 8 registros con
  ↪ valores perdidos en la variable uso_suelo

plot(st_geometry(andalucia_proj),reset=F)
dataset |> filter(is.na(uso_suelo)) |> st_geometry() |>
  ↪ plot(pch=16,col="red",add=T)
# De nuevo se observa que se encuentran en los límites de Andalucía con
  ↪ la costa

# Valores perdidos en NDVI -----
# Se muestran en el mapa
plot(st_geometry(andalucia_proj),reset=F)
dataset |> filter(is.na(NDVI)) |> st_geometry() |>
  ↪ plot(pch=16,col="red",add=T)

# Gráfico de NDVI medio cada mes
NDVI_mes = datos |>
  st_drop_geometry() |>
  mutate(mes = month(date),
         año = year(date)) |>
  group_by(año,mes) |>
  summarise(NDVI_mes = mean(na.omit(NDVI))) |>
  ungroup() |>
  mutate(date = dmy(paste(01,mes,año,sep="/")))

NDVI_mes |>
  ggplot(aes(x=date,y=NDVI_mes)) +
  geom_line()+
  scale_x_date(date_breaks = "6 month",date_labels = "%y %b")+
  theme(axis.text.x = element_text(angle = 90))

```

```

# 2008 tiene un NDVI especialmente bajo, puede deberse a numerosos
↪ factores:
#   - Que efectivamente sea un año especialmente seco
#   - Las características de la muestra seleccionada ese año
#   - Errores de medición
#   - ...

# La mayor parte de los valores perdidos en la variable uso_suelo son
↪ debidos a que el archivo tiff para ese mes no está disponible en la
↪ REDIAM. Los meses de los que no se dispone del ráster NDVI son:
↪ "2003-01", "2003-04", "2017-02", "2018-11", "2020-11", "2021-12",
↪ "2022-03" y "2022-12".

# Eliminación registros con valores perdidos -----
# Tras explorar otras opciones finalmente se opta por eliminar los
↪ registros
# que contienen valores perdidos:

datos = datos %>% drop_na()

# Almacenamiento del conjunto de datos depurados -----
# Se guarda el conjunto de datos depurados
save(datos,
      file = paste0("salidas_intermedias/datos_strat_depurados_geom_",
                    Sys.Date(), ".RData"))

```

1.4. Análisis exploratorio

```

# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos
library(sf) # Vector data
library(terra) # Raster data
library(mapSpain) # Polígonos de regiones de España
library(magrittr) # Operador %<>%
library(skimr) # Resumen de datos
library(corrplot) # Gráfico de correlaciones
library(GGally) # Coordenadas paralelas
library(ggpubr) # Función ggarrange

# Carga de los datos -----
load("salidas_intermedias/datos_strat_depurados_geom_2024-05-03.RData")

# Resumen numérico -----
datos %>% st_drop_geometry %>% skim(.data_name = "datos")

```

1.4.1. Variable objetivo

```
# Distribución temporal -----
# Mensual:
g_mes <- datos %>%
  st_drop_geometry() %>%
  # filter(fire==1) %>%
  count(month(date,label=T),fire) %>%
  rename("mes" = "month(date, label = T)") %>%
  ggplot(aes(x = mes,y = n,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  # theme(axis.text.x = element_text(angle = 90)) +
  scale_fill_hue(direction = -1) +
  theme_minimal() +
  xlab("Mes") +
  ylab("Número de observaciones")

g_mes

# Anual
g_year <- datos %>%
  st_drop_geometry() %>%
  # filter(fire==1) %>%
  count(year(date),fire) %>%
  rename("año" = "year(date)") %>%
  ggplot(aes(x = año,y = n,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_x_continuous(breaks=2002:2022) +
  geom_smooth(se=F,aes(color=fire),alpha=0.1) +
  scale_color_manual(values=c("darkblue","darkred")) +
  scale_fill_hue(direction = -1) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust=1)) +
  xlab("Año") +
  ylab("Número de observaciones")
g_year

# En 2007 no se han generado observaciones positivas
# Causa: En el shapefile que contiene los incendios producidos en 2007
→ solo hay 4 observaciones y ninguna tenía la fecha, por lo que estas
→ no han podido utilizarse

# Valores muy bajos en 2008 y 2010, revisar
# 2010: correcto, en el archivo con los polígonos de incendios en 2010
→ solo hay 26 observaciones
# 2008: en el archivo relativo a ese año hay 37 observaciones, pero 11
→ de ellas no tienen la fecha de inicio, por lo que no se han podido
→ utilizar
```

```

# Día de la semana
g_dia <- datos %>%
  st_drop_geometry() %>%
  # filter(fire==1) %>%
  count(weekdays(date),fire) %>%
  rename("dia" = "weekdays(date)") %>%
  ggplot(aes(x = dia,y = n,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_x_discrete(limits=c("lunes", "martes", "miércoles", "jueves",
    ↪ "viernes", "sábado", "domingo")) +
  theme(axis.text.x = element_text(angle = 45, vjust = 0.5, hjust=0.5)) +
  # geom_smooth(se=F) +
  scale_fill_hue(direction = -1) +
  theme_minimal() +
  xlab("Día") +
  ylab("Número de observaciones")
g_dia

# Para mostrar los tres gráficos juntos
ggarrange(g_dia,g_mes,g_year,ncol=1,common.legend = T,legend = "bottom")

# Distribución temporal -----
# Se cargan los polígonos de las provincias
and <- esp_get_ccaa(ccaa = "Andalucía") %>% st_transform(st_crs(datos))
prov <- esp_get_prov() %>% filter(nuts2.name=="Andalucía") %>%
  ↪ st_transform(st_crs(datos))

# Casos positivos
g1 = ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos %>% filter(fire==1),size = 1, alpha =
    ↪ 0.4,col="red")+
  ggtitle("Distribución espacial de casos positivos") +
  theme_minimal()

# Casos negativos
g0 = ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos %>% filter(fire==0),size = 1, alpha =
    ↪ 0.4,col="blue") +
  ggtitle("Distribución espacial de casos negativos") +
  theme_minimal()

# Ambos gráficos juntos:
ggarrange(g1,g0,nrow=2)

```

1.4.2. Análisis univariantes

T2M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=T2M),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de T2M por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

Las temperaturas más elevadas se encuentran en el interior.

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_T2M = mean(T2M),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_T2M,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
# + theme(axis.text.x = element_text(angle = 45, vjust = 0.5,
  ↪ hjust=0.5))
```

En prácticamente todos los meses, la media de temperaturas en las observaciones positivas es mayor que en las observaciones negativas. Las temperaturas son más altas en los meses de verano, como cabía esperar.

RH2M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=RH2M),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=F)) +
```

```
# scale_color_gradient(low="blue", high="red")+
ggtitle("Distribución espacial de RH2M por mes") +
theme_minimal() +
theme(axis.text.x=element_blank(),
      axis.ticks.x=element_blank(),
      axis.text.y=element_blank(),
      axis.ticks.y=element_blank(),
      panel.grid.major = element_blank(),
      panel.grid.minor = element_blank())
```

La humedad del aire es mayor en las de costa. Las zonas más secas se encuentran en las zonas de interior del norte de Andalucía.

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_RH2M = mean(RH2M),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_RH2M,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
# + theme(axis.text.x = element_text(angle = 45, vjust = 0.5,
  ↪ hjust=0.5))
```

En prácticamente todos los meses, la humedad del aire media entre las observaciones positivas es menor que en las observaciones negativas. La humedad del aire disminuye significativamente en verano.

GWETTOP

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=GWETTOP),size = 1, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=F)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de GWETTOP por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

Las zonas con mayor humedad superficial de suelo son las que se encuentran en la costa mediterránea. Las zonas con un suelo más seco son las que se encuentran al norte de la cuenca el Guadalquivir, destacando la provincia de Huelva (hay que tener en cuenta que también es una zona en la que hay muchos incendios, la mayoría de los cuales se produce en verano, por lo que hay una gran concentración de observaciones durante el periodo estival, lo que podría influir en el hecho de que se observen tantas observaciones con valores tan bajos de la humedad superficial de suelo).

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_GWETTOP = mean(GWETTOP),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_GWETTOP,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
```

En general, la humedad superficial de suelo media entre los casos positivos es inferior que entre los casos negativos. Esto es especialmente evidente entre los meses de primavera y otoño. En los meses de invierno esto no está tan claro, incluso parece revertirse la tendencia.

WS10M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos,
    ↪ aes(color=WS10M,alpha=WS10M,size=as.numeric(ifelse(WS10M<7.5,1,1.2))))
    ↪ +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
  facet_wrap(~month(date,label=TRUE))+
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de WS10M por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank()) +
  guides(size="none",alpha="none")
```

Los valores más elevados de la velocidad del viento a 10m de altura se dan en las zonas costeras.


```

datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_WS10M = mean(WS10M),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_WS10M,fill=fire)) +
  geom_col(position="dodge",alpha=0.8)+
  scale_fill_hue(direction = -1) +
  theme_minimal()

```

En todos los meses, los valores medios de la velocidad del viento a 10m sobre la superficie son significativamente mayores en las observaciones positivas.

WD10M

```

ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=WD10M),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE))+
  # scale_color_stepsn(colours = rainbow(8,rev=T)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de WD10M por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank()) +
  guides(color = guide_legend(override.aes = list(size = 5))) +
  scale_color_viridis_d(option="turbo")

```

```

# Quisiera tener la dirección mayoritaria por mes y si hay incendio o no
↪
mode <- function(x) { names(which.max(table(x))) }

```

```

datos_mode_WD10M = datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(mode_WD10M = mode(WD10M))

tibble(mes = datos_mode_WD10M[datos_mode_WD10M$fire==1,1],
       fire1 = datos_mode_WD10M[datos_mode_WD10M$fire==1,3],
       fire0 = datos_mode_WD10M[datos_mode_WD10M$fire==0,3])

```

```
# No parece aportar ninguna información relevante
```

PRECTOTCORR

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos,
    ↪ aes(color=PRECTOTCORR,size=PRECTOTCORR,alpha=PRECTOTCORR)) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=F)) +
  guides(size="none") +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de PRECTOTCORR por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
    axis.ticks.x=element_blank(),
    axis.text.y=element_blank(),
    axis.ticks.y=element_blank(),
    panel.grid.major = element_blank(),
    panel.grid.minor = element_blank()) +
  guides(alpha="none")
```

En la gran mayoría de las observaciones no se han observado precipitaciones. Se observan algunos valores positivos de precipitaciones distribuidos por el territorio andaluz, alcanzándose los máximos en observaciones localizadas en las cordilleras béticas.

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_PRECTOTCORR = mean(PRECTOTCORR),
    Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_PRECTOTCORR,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
```

Se observa una clara diferencia en la media mensual de precipitaciones en ambas clases en todos los meses, siendo mucho mayores entre las observaciones negativas. En los meses de verano esto sigue siendo cierto, si bien las diferencias se suavizan significativamente, ya que en ambos clases las precipitaciones son reducidas.

NDVI

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=NDVI),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de NDVI por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

Los valores más elevados del NDVI se encuentran en el norte de la comunidad (Sierra Morena y Sierra de Aracena) y en la zona sur-centro. Los valores son especialmente elevados en la Sierra de Grazalema y en las marismas del Guadalquivir y especialmente bajos en el este de la comunidad (Almería).

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_NDVI = mean(NDVI),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_NDVI,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
# theme(axis.text.x = element_text(angle = 45, vjust = 0.5,
  ↪ hjust=0.5))
```

El valor del NDVI disminuye en los meses de verano y alcanza su máximo en los meses de invierno. No se observa claramente una relación entre el NDVI y la clase de la observación en la muestra.

poblacion

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=poblacion,size =
  ↪ poblacion,alpha=poblacion/median(poblacion))) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
```

```
guides(size="none",alpha="none") +  
# scale_color_gradient(low="blue", high="red")+  
ggtitle("Distribución espacial de poblacion") +  
theme_minimal()  
  
by(datos$poblacion,datos$fire,summary)
```

En la gran mayoría del territorio se observan niveles de población inferiores a 20.000 habitantes por municipio. Destacan las capitales de provincia por tener valores significativamente más elevados.

dens_poblacion

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dens_poblacion, size= dens_poblacion,  
    ↪ alpha=dens_poblacion)) +  
  scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  # scale_color_gradient(low="blue", high="red")+  
  ggtitle("Distribución espacial de dens_poblacion") +  
  theme_minimal()  
  
by(datos$dens_poblacion,datos$fire,summary)
```

Se puede observar una distribución espacial similar a la cantidad de población. Se observa una mayor densidad de población en las zonas de costa y en las capitales de provincia.

pendiente

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=pendiente, size= pendiente,  
    ↪ alpha=pendiente)) +  
  scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de pendiente") +  
  theme_minimal()
```

elevacion

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=elevacion, size= elevacion,
    ↪ alpha=elevacion)) +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de elevacion") +
  theme_minimal()
```

curvatura

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=curvatura, alpha=curvatura)) +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de curvatura") +
  theme_minimal()
```

dist_carretera

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=dist_carretera, alpha=dist_carretera))
  ↪ +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de dist_carretera") +
  theme_minimal()
```

dist_electr

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=dist_electr, alpha=dist_electr)) +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de dist_electr") +
  theme_minimal()
```

dist_camino

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_camino, alpha=dist_camino)) +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_camino") +  
  theme_minimal()
```

dist_sendero

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_sendero, alpha=dist_sendero)) +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_sendero") +  
  theme_minimal()
```

dist_poblacion

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_poblacion, alpha=dist_poblacion))  
  ↪ +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_poblacion") +  
  theme_minimal()
```

dist_ferrocarril

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_ferrocarril,  
  ↪ alpha=dist_ferrocarril)) +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_ferrocarril") +  
  theme_minimal()
```

1.4.3. Análisis multivariantes

Variables numéricas

```

datos_numeric = datos %>%
  select(where(is.numeric)) %>%
  st_drop_geometry()

# Correlaciones -----
R = cor(datos_numeric)
corrplot(R,method = "ellipse",type = "lower")
summary(R-diag(diag(R)))
# Las variables más correlacionadas en la muestra son T2M con RH2M
→ (negativamente, -0.71), T2M con GWETTOP (negativamente, -0.69) y
→ GWETTOP con R2HM (positivamente, 0.68). Tiene sentido que la humedad
→ del aire a dos metros esté correlacionada positivamente con la
→ humedad del suelo y que ambas estén negativamente correlacionadas
→ con la temperatura del aire. También están correladas la población
→ con la densidad de población (positivamente,0.63).

# Gráfico de coordenadas paralelas -----
datos |>
  select(fire,where(is.numeric)) |>
  ggparcoord(columns=2:19,alphaLines=0.1,groupColumn = "fire") +
  xlab('') +
  ylab('') +
  scale_x_discrete(labels=colnames(datos_numeric)) +
  scale_color_hue(direction = -1) +
  # guides(color = "none")+
  theme_minimal() +
  ggtitle("Tipificación a normal estándar (por defecto)") +
  theme(plot.title = element_text(size = 9),
        axis.text.x = element_text(angle = 90))

# Boxplots -----
boxplots <- map(names(datos_numeric), ~ ggplot(datos, aes(x = fire, y =
→ .data[[.x]]),fill=fire)) +
  geom_boxplot() +
  scale_fill_hue(direction = -1) +
  guides(fill="none") +
  labs(title = paste(.x, "~ fire"))
ggarrange(plotlist = boxplots,ncol=6,nrow=3)

# PCA -----
pca <- princomp(datos_numeric,cor=T)
summary(pca)

```

```
# Se necesitan al menos 11 componentes principales para explicar el 80%
↪ de la variabilidad de las 18 variables numéricas de la muestra
↪ (tipificadas) y al menos 14 para explicar el 90%. Esto refleja, la
↪ complejidad del conjunto de datos.
```

Variables categóricas

```
datos_categ <- datos %>%
  select(WD10M,orientacion,enp,uso_suelo) %>%
  st_drop_geometry()

# Histogramas -----
histogramas <- map(names(datos_categ),
  ~ ggplot(datos, aes(x = .data[[.x]],
                     fill = fire)) +
    geom_bar(position = "dodge", alpha = 0.8) +
    scale_fill_hue(direction = -1) +
    theme_minimal() +
    labs(title = .x) +
    theme(axis.text.x = element_text(size=7)))

ggarrange(plotlist = histogramas, ncol = 2, nrow =
  ↪ ceiling(length(histogramas)/2))
```

1.5. Modelos

```
# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos
library(sf) # Vector data
library(tidymodels) # Ecosistema para la construcción de modelos
library(akima) # Función interp
library(magrittr) # Operador %<>%
library(ggpubr) # Función ggarrange
library(knitr) # Función kable

# Carga de datos -----
load("salidas_intermedias/datos_strat_depurados_geom_2024-05-03.RData")

# Agrupación clases uso_suelo -----
# Nos quedamos con los 7 niveles del factor más frecuentes (clases 2 y
↪ 3)
datos <- datos |>
```



```

mutate(uso_suelo = fct_lump(uso_suelo,
                           n = 7,
                           other_level= "Otro"))

# Funciones para la evaluación de modelos -----
# Función para obtener las medidas de rendimiento de los modelos a
  ↪ partir de un objeto predict
get_metrics <- function(pred) {
  list(
    res = tibble(
      roc_auc = pred |> roc_auc(truth = fire, .pred_0) |>
        ↪ pull(.estimate),
      accuracy = pred |> accuracy(truth = fire, .pred_class) |>
        ↪ pull(.estimate),
      recall = pred |> sensitivity(truth = fire,
        ↪ .pred_class,event_level="second") |> pull(.estimate),
      specificity = pred |> spec(truth = fire,
        ↪ .pred_class,event_level="second") |> pull(.estimate),
      precision = pred |> precision(truth = fire,
        ↪ .pred_class,event_level="second") |> pull(.estimate)),
      conf_mat = pred |> conf_mat(truth = fire, .pred_class))
}

# Función para mostrar gráficamente los resultados del tuning de un
  ↪ modelo con dos parámetros
tuning_plot = function(mod_res) {
  datos_metrics = mod_res %>%
    collect_metrics()

  plots = list()

  for (metric in unique(datos_metrics$.metric)) {

    datos = datos_metrics %>%
      filter(.metric==metric)

    # Interpolación los datos faltantes
    datos_interp <- interp(datos[[1]], datos[[2]], datos$mean)

    # Crear un nuevo dataframe con los datos interpolados
    datos_interp_df <- data.frame(
      expand.grid(x = datos_interp$x, y = datos_interp$y), z =
        ↪ as.vector(datos_interp$z))

    # Crear el gráfico de mapa de calor con interpolación
    p = ggplot(datos_interp_df, aes(x = x, y = y, fill = z)) +
      geom_tile() +

```

```

    scale_fill_viridis_c(option = "turbo", name = NULL, na.value =
      ↪ "transparent")+
    labs(title = "",
         x = colnames(datos)[1],
         y = colnames(datos)[2],
         fill = metric) +
    theme_minimal()

    plots[[metric]] = p
  }
  ggarrange(plotlist = plots,
            labels=c("Accuracy","Specificity","ROC-AUC","Recall"),
            align = "hv")
}

```

1.5.1. Partición temporal entrenamiento-validación-test

```

set.seed(123) # Se fijan semillas para que sea reproducible

splits = initial_validation_time_split(datos,
                                       prop=c(0.6,0.2))

training <- training(splits) %>% st_drop_geometry()
val_set <- validation_set(splits) %>% st_drop_geometry()
test <- testing(splits) %>% st_drop_geometry()

```

1.5.2. Regresión logística con penalización

```

# 1º Definimos el modelo:
lr_mod <-
  logistic_reg(penalty = tune(), mixture = tune()) %>%
  set_engine("glmnet")

# 2º Creamos la receta
lr_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  # step_holiday(date, holidays = holidays) %>%
  step_rm(date, cod_municipio, municipio) %>% # Se eliminan variables
  ↪ identificadoras
  step_dummy(all_nominal_predictors()) %>% # Se crean variables dummy
  ↪ para los factores
  step_lincomb() %>% # Elimina variables con dependencia lineal exacta

```

```

step_corr() %>% # Elimina variables con correlación superior a 0.9
step_zv(all_predictors()) %>% # Eliminar variables con varianza nula
step_normalize(all_predictors()) # Se normalizan todos los predictores

# 3º Creamos el workflow
lr_workflow <-
  workflow() %>%
  add_model(lr_mod) %>%
  add_recipe(lr_recipe)

# 4º Creamos el grid para los parámetros
lr_reg_grid <- expand_grid(penalty = 10^seq(-4, -1, length.out = 10),
                          mixture = seq(0,1,length.out=10))

# 5º Ajustamos el modelo
lr_res <-
  lr_workflow %>%
  tune_grid(val_set,
            grid = lr_reg_grid,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# 6º Evaluación de modelos
tuning_plot(lr_res)

lr_res |>
  collect_metrics() |>
  group_by(.metric)|>
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) |>
  summarise(max = max(mean),min=min(mean))

# 7º Selección del mejor modelo
lr_best <-
  lr_res %>%
  select_best(metric="accuracy")
lr_best

# Extraer coeficientes
lr_workflow %>%
  finalize_workflow(lr_best) %>%
  fit(training) %>%
  extract_fit_parsnip() %>%
  tidy() %>%
  print(n=100)

```

1.5.3. Regresión logística con penalización + PCA

```
# 1º Creamos el modelo
lr_pca_mod <-
  logistic_reg(penalty = tune(), mixture = tune()) %>%
  set_engine("glmnet")

# 2º Creamos la receta
lr_pca_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  # step_holiday(date, holidays = holidays) %>%
  step_rm(date, cod_municipio, municipio) %>% # Se eliminan variables
  ↪ identificadoras
  step_dummy(all_nominal_predictors()) %>% # Se crean variables dummy
  ↪ para los factores
  step_lincomb() %>% # Elimina variables con dependencia lineal exacta
  step_corr() %>% # Elimina variables con correlación superior a 0.9
  step_zv(all_predictors()) %>% # Eliminar variables con varianza nula
  step_normalize(all_predictors()) %>% # Se normalizan todos los
  ↪ predictores
  step_pca(all_numeric_predictors(), num_comp = tune())

# 3º Creamos el workflow
lr_pca_workflow <-
  workflow() %>%
  add_model(lr_pca_mod) %>%
  add_recipe(lr_pca_recipe)

# 4º Creamos el grid para los parámetros
lr_pca_reg_grid <- expand_grid(penalty = 10^seq(-4, -1, length.out = 10),
                             mixture = seq(0, 1, length.out = 10),
                             num_comp = c(20, 25, 30, 35, 40, 45, 50))

# 5º Ajustamos el modelo
lr_pca_res <-
  lr_pca_workflow %>%
  tune_grid(val_set,
            grid = lr_pca_reg_grid,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# 6º Evaluación modelos
lr_pca_res |>
  collect_metrics() |>
  group_by(.metric) |>
```

```

summarise(max = max(mean),min=min(mean))

# 7º Selección del mejor modelo
lr_pca_best <-
  lr_pca_res %>%
  select_best(metric="accuracy")
lr_pca_best

```

1.5.4. Árboles de decisión

```

# 1º Creamos el modelo
dt_mod <-
  decision_tree(cost_complexity = tune()) %>%
  set_engine("rpart") %>%
  set_mode("classification")

# 2º Creamos la receta
dt_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  # step_holiday(date) %>%
  step_rm(date, cod_municipio, municipio)

# 3º Creamos el workflow
dt_workflow <-
  workflow() %>%
  add_model(dt_mod) %>%
  add_recipe(dt_recipe)

# 4º Se ajusta el modelo
set.seed(345)
dt_res <-
  dt_workflow %>%
  tune_grid(val_set,
            grid = 10,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# 5º Se evalúan los modelos obtenidos
dt_res |>
  collect_metrics() |>
  group_by(.metric) |>
  mutate(.metric = ifelse(.metric == "recall", "spec",
                          ifelse(.metric == "spec", "recall",
                                .metric))) |>

```

```
summarise(max = max(mean),min=min(mean))

# Gráfico del ajuste
dt_res %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) |>
  ggplot(aes(x = cost_complexity, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  scale_x_log10(labels = scales::label_number())+
  theme_minimal()

# 6º Selección del mejor modelo
dt_best <- dt_res |>
  select_best(metric = "accuracy")
dt_best
```

1.5.5. Bosques aleatorios

```
# Detectar el número de núcleos para trabajar en paralelo
cores <- parallel::detectCores()
cores

# Construimos el modelo, especificando el número de núcleos a usar en la
↪ computación en paralelo de forma que la computación sea más
↪ eficiente

# ETAPA 1: fijado mtry=4, se ajusta min_n
# -----

# 1º Construir el modelo
rf_mod1 <-
  rand_forest(mtry = 4, min_n = tune(), trees = 1000) %>%
  set_engine("ranger", num.threads = cores) %>%
  set_mode("classification")

# 2º Construir la receta con el preprocesamiento
rf_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date,features = c("dow", "month")) %>%
  # step_holiday(date)%>%
  step_rm(date, cod_municipio, municipio)
```

```

# No normalizamos en este caso pues no es necesario

# 3º Ensamblar todo con workflow
rf_workflow1 <-
  workflow() %>%
  add_model(rf_mod1) %>%
  add_recipe(rf_recipe)

# 4º Train and tune
set.seed(345)

rf_res1 <-
  rf_workflow1 %>%
  tune_grid(val_set,
            grid = expand_grid(min_n = seq(1000,2500,100)),
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# Resultados del tuning

rf_tuning1 <- rf_res1 |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))
rf_tuning1

# plot

rf_plot1 <-
  rf_res1 %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) %>%
  ggplot(aes(x = min_n, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  theme_minimal()+
  labs(title = "Etapa 1\nFijado mtry = 4, se ajusta min_n")

# Mejor modelo
rf_best1 <-
  rf_res1 %>%
  select_best(metric = "spec")
rf_best1

```

```
rf_metrics1 <- rf_res1 |>
  collect_predictions(parameters = rf_best1) |>
  get_metrics()
rf_metrics1

# ETAPA 2: fijado min_n de la etapa anterior, se ajusta mtry
# -----

# 1º Se construye el modelo
rf_mod2 <-
  rand_forest(mtry = tune(), min_n = rf_best1$min_n, trees = 1000) %>%
  set_engine("ranger", num.threads = cores) %>%
  set_mode("classification")

# 2º Se usa la misma receta que antes

# 3º Ensamblar todo con workflow
rf_workflow2 <-
  workflow() %>%
  add_model(rf_mod2) %>%
  add_recipe(rf_recipe)

# 4º Train and tune
set.seed(345)

rf_res2 <-
  rf_workflow2 %>%
  tune_grid(val_set,
            grid = expand_grid(mtry = 1:10),
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# Resultados del tuning

rf_tuning2 <- rf_res2 |>
  collect_metrics() |>
  group_by(.metric) |>
  summarise(max = max(mean), min = min(mean))

rf_tuning2

# plot
rf_plot2 <-
  rf_res2 %>%
```



```

collect_metrics() %>%
mutate(.metric = ifelse(.metric == "recall","spec",
                        ifelse(.metric == "spec","recall",
                              .metric))) %>%

ggplot(aes(x = mtry, y = mean,col=.metric)) +
geom_point() +
geom_line() +
ylab("") +
theme_minimal()+
labs(title = paste0("Etapa 2\nFijado min_n = ", rf_best1$min_n, " se
  ↪ ajusta mtry"))

# Mejor modelo
rf_best2 <-
  rf_res2 %>%
  select_best(metric = "spec")
rf_best2

rf_metrics2 <- rf_res2 |>
  collect_predictions(parameters = rf_best2) |>
  get_metrics()

rf_metrics2

# -----

# Plots
ggarrange(rf_plot1,rf_plot2,nrow=1,common.legend = T,legend = "bottom")

```

1.5.6. k-Nearest Neighbours

```

# 1º Definimos el modelo:
knn_mod <-
  nearest_neighbor(neighbors = tune()) %>%
  set_engine("kknn") %>%
  set_mode("classification")

# 2º Creamos la receta
knn_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date,features = c("dow","month")) %>%
  # step_holiday(date, holidays = holidays) %>%
  step_rm(date,cod_municipio,municipio) %>% # Se eliminan variables
  ↪ identificadoras
  step_dummy(all_nominal_predictors()) %>% # Se crean variables dummy
  ↪ para los factores

```

```

step_lincomb() %>% # Elimina variables con dependencia lineal exacta
step_corr() %>% # Elimina variables con correlación superior a 0.9
step_zv(all_predictors()) %>% # Eliminar variables con varianza nula
step_normalize(all_predictors()) # Se normalizan todos los predictores
# En este caso, step_lincomb, step_corr y step_zv no tienen ningún
→ efecto, pero se dejan
# por ser una buena práctica

# 3º Creamos el workflow
knn_workflow <-
  workflow() %>%
  add_model(knn_mod) %>%
  add_recipe(knn_recipe)

# 4º Train and tune
set.seed(345)
knn_res <-
  knn_workflow %>%
  # fit(training)
  tune_grid(val_set,
            grid = expand_grid(neighbors = c(1,10,25,seq(25,400,25))),
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# 5º Evaluación de los modelos
knn_res |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))

knn_res %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                        ifelse(.metric == "spec","recall",
                              .metric))) %>%

  # filter(.metric == "accuracy")%>%
  ggplot(aes(x = neighbors, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  theme_minimal()

# 6º Selección del mejor modelo
knn_best <- knn_res |>
  select_best(metric = "accuracy")
knn_best

```

1.5.7. SVM lineal

```

# 1º Construir el modelo
svm_mod <-
  svm_linear(cost = tune()) %>%
  set_engine("kernlab") %>%
  set_mode("classification")

# 2º Construir la receta con el preprocesamiento
svm_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  step_rm(date, cod_municipio, municipio) %>%
  step_dummy(all_nominal_predictors()) %>%
  step_zv(all_predictors()) %>%
  step_normalize(all_predictors())

# 3º Ensamblar todo con workflow
svm_workflow <-
  workflow() %>%
  add_model(svm_mod) %>%
  add_recipe(svm_recipe)

# 4º Train and tune
set.seed(345)
svm_res <-
  svm_workflow %>%
  tune_grid(val_set,
            grid = 15,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# 5º Evaluación de resultados del tuning
svm_res |>
  collect_metrics() |>
  group_by(.metric) |>
  summarise(max = max(mean), min = min(mean))

svm_plot <-
  svm_res %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall", "spec",
                          ifelse(.metric == "spec", "recall",
                                .metric))) %>%
  # filter(.metric == "accuracy") %>%
  ggplot(aes(x = cost, y = mean, col = .metric)) +
  geom_point() +

```

```
geom_line() +  
ylab("") +  
theme_minimal()  
svm_plot  
  
# 6º Selección del mejor modelo  
svm_best <-  
  svm_res %>%  
  select_best(metric="accuracy")  
svm_best
```

1.5.8. SVM radial

```
# 1º Construir el modelo  
svm_rbf_mod <-  
  svm_rbf(cost = tune(), rbf_sigma = tune()) %>%  
  set_engine("kernlab") %>%  
  set_mode("classification")  
  
# 2º Construir la receta con el preprocesamiento  
svm_rbf_recipe <-  
  recipe(fire ~ ., data = training) %>%  
  step_date(date, features = c("dow", "month")) %>%  
  step_rm(date, cod_municipio, municipio) %>%  
  step_dummy(all_nominal_predictors()) %>%  
  step_lincomb() %>% # Elimina variables con dependencia lineal exacta  
  step_corr() %>% # Elimina variables con correlación superior a 0.9  
  step_zv(all_predictors()) %>%  
  step_normalize(all_predictors())  
  
# 3º Ensamblar todo con workflow  
svm_rbf_workflow <-  
  workflow() %>%  
  add_model(svm_rbf_mod) %>%  
  add_recipe(svm_rbf_recipe)  
  
# 4º Train and tune  
set.seed(345)  
svm_rbf_res <-  
  svm_rbf_workflow %>%  
  tune_grid(val_set,  
    grid = 8,  
    control = control_grid(save_pred = TRUE),  
    metrics = metric_set(accuracy, roc_auc, recall, spec))
```

```
# 5º Evaluación de resultados del tuning
svm_rbf_res |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))

# 6º Selección del mejor modelo
svm_rbf_best <-
  svm_rbf_res %>%
  select_best(metric="accuracy")

svm_rbf_best
```

1.5.9. Comparación

```
models = tibble(model_name =
  ↪ c("lr","lr_pca","dt","rf","svm_linear","svm_rbf","knn"),
  models_tune = list(lr_res, lr_pca_res, dt_res, rf_res2,
  ↪ svm_res, svm_rbf_res, knn_res),
  models_workflow = list(lr_workflow, lr_pca_workflow,
  ↪ dt_workflow, rf_workflow2, svm_workflow,
  ↪ svm_rbf_workflow, knn_workflow))

# save(models, file="salidas_intermedias/all_models.RData")

load("salidas_intermedias/all_models.RData")
models = models %>%
  mutate(best_tuning = map(models_tune,
    function(x) select_best(x, metric =
    ↪ "accuracy")),
  best_metrics = map2(models_tune,
    best_tuning,
    ~ collect_predictions(.x,parameters = .y)
    ↪ %>%
    get_metrics() %>%
    extract2(1)), # Para extraer solo las
    ↪ medidas y no la matriz de confusión
  roc = map2(models_tune,
    best_tuning,
    ~ collect_predictions(.x,parameters = .y) %>%
    roc_curve(fire, .pred_0))
)

# métricas
metrics = models %>%
```

```

select(model_name,best_metrics) %>%
unnest(best_metrics)
kable(metrics,digits=3)

# curva roc
metrics %>%
pivot_longer(cols = c(roc_auc, accuracy, recall, specificity,
  ↪ precision),
              names_to = "metric") %>%
ggplot(aes(x = metric, y = value, group = model_name)) +
geom_line(aes(col = model_name),size=1) +
geom_point(aes(col = model_name),size=2.3) +
scale_color_viridis_d(option="turbo") +
geom_vline(xintercept=1:5, linetype="dotted") +
labs(col = "Modelo", title = "Métricas sobre validación") +
theme_minimal() +
theme(axis.line.x = element_line(color="black", size = 1),
      axis.line.y = element_line(color="black", size = 1))

# plot medidas
models %>% select(model_name,roc) %>% unnest(roc) %>%
ggplot(aes(x = 1 - specificity, y = sensitivity, col = model_name)) +
geom_path(lwd = 1, alpha = 0.7) +
geom_abline(lty = 3) +
coord_equal() +
scale_color_viridis_d(option="turbo") +
labs(color="Modelo")+
# scale_color_viridis_d(option = "turbo",name="Modelo") +
theme_minimal() +
theme(axis.line.x = element_line(color="black", size = 1),
      axis.line.y = element_line(color="black", size = 1))+
ggtitle("Curva ROC en validación")

```

1.5.10. Test

Se unen los conjuntos training y validation para entrenar el modelo final

```

set.seed(345)
models = models %>%
  mutate(final_workflow = map2(models_workflow,
                                best_tuning,
                                finalize_workflow),
         last_fit = map(final_workflow,
                        function(x)
                          ↪ last_fit(x,splits,add_validation_set=T)),
         test_metrics = map(last_fit,

```

```

        ~collect_predictions(.x) %>%
        get_metrics() %>%
        extract2(1)), # Para extraer solo las
        ↪ medidas
test_roc = map(last_fit,
        ~collect_predictions(.x) %>%
        roc_curve(fire, .pred_0))
)

# save(models, file="salidas_intermedias/all_models_test.RData")

# metricas en test
test_metrics = models %>%
  select(model_name, test_metrics) %>%
  unnest(test_metrics)

kable(test_metrics,digits=3)

# plot
test_metrics %>%
  pivot_longer(cols = c(roc_auc, accuracy, recall, specificity,
    ↪ precision),
    names_to = "metric") %>%
  ggplot(aes(x = metric, y = value, group = model_name)) +
  geom_line(aes(col = model_name),size=1) +
  geom_point(aes(col = model_name),size=2.3) +
  scale_color_viridis_d(option="turbo") +
  geom_vline(xintercept=1:5, linetype="dotted") +
  labs(col = "Modelo", title = "Métricas sobre test") +
  theme_minimal() +
  theme(axis.line.x = element_line(color="black", size = 1),
    axis.line.y = element_line(color="black", size = 1))

# roc
models %>%
  select(model_name,test_roc) %>%
  unnest(test_roc) %>%
  ggplot(aes(x = 1 - specificity, y = sensitivity, col = model_name)) +
  geom_path(lwd = 1, alpha = 0.7) +
  geom_abline(lty = 3) +
  coord_equal() +
  scale_color_viridis_d(option="turbo") +
  labs(color="Modelo")+
  # scale_color_viridis_d(option = "turbo",name="Modelo") +
  theme_minimal() +
  theme(axis.line.x = element_line(color="black", size = 1),
    axis.line.y = element_line(color="black", size = 1))+

```

```
ggtitle("Curva ROC en test")
```

Para calcular la medida de importancia de las variables en bosque aleatorio. No se hace desde el principio para que la computación sea más rápida.

```
# Se hace el last_fit manualmente:
cores = 8

# last model
last_rf_mod <- rand_forest(mtry = rf_best2$mtry, min_n = rf_best1$min_n,
  ↪ trees = 1000) %>%
  set_engine("ranger", num.threads = cores, importance="impurity") %>%
  set_mode("classification")

# last workflow
last_rf_workflow <-
  rf_workflow2 %>%
  update_model(last_rf_mod)

# last fit
set.seed(345)
last_rf_fit <-
  last_rf_workflow %>%
  last_fit(splits,
    add_validation_set = T)

# VIP
last_rf_fit %>%
  extract_fit_parsnip() %>%
  vip(num_features = 50, aesthetics = list(fill="lightblue")) +
  theme_minimal()
```

1.6. Aplicación de los modelos

```
# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos
library(sf) # Vector data
library(tidymodels) # Ecosistema para la construcción de modelos
library(ggpubr) # Función ggarrange
library(knitr) # Función kable
library(skimr) # Función skim
library(terra)

# Carga de datos -----
```



```
load("salidas_intermedias/datos_strat_depurados_geom_2024-04-27.RData")

# Polígono de Andalucía -----
and <- esp_get_ccaa(ccaa = "Andalucía") %>%
  st_transform(st_crs(datos))
```

1.6.1. Visión general del desempeño del modelo

Se construye una rejilla de puntos con una separación de 10km entre ellos (en la dirección Norte-Sur y Este-Oeste). En cada uno de los puntos se predice la probabilidad de incendio el día 15 de cada mes usando los mejores modelos construidos. Para ello, primero hay que asignar a cada punto los valores correspondientes de las variables predictoras consideradas.

```
# grid de puntos 10km x 10km de andalucía
grid = st_make_grid(and,
                    cellsize = c(10000,10000), # 10000
                    what = "centers")[and]

g = and %>%
  ggplot() +
  geom_sf() +
  theme_minimal()

g +
  geom_sf(data = grid,color="red",size=0.6) +
  labs(title = "Malla de puntos con una resolución de 10km x 10km")
```

Se va a analizar cada observación el 15 de cada mes.

```
sample = NULL

for (m in 1:12) {
  if (is.null(sample)){
    sample <- tibble(date = rep(ymd(paste("2022",m,"15",sep="/"))),
                        geometry = grid) %>% st_sf()
  } else
    sample <- sample %>%
      bind_rows(tibble(date = rep(ymd(paste("2022",m,"15",sep="/"))),
                        geometry = grid))
}
```

Se le asocian todas las variables correspondientes a cada observación.

```
source("scripts/strat/fun_asignar_variables.R")
full_grid = asignar_variables(sample)
```

Se imputan los valores faltantes de NDVI asignándoles los del año anterior, ya que faltan los archivos de marzo y diciembre de 2022.

```
# La siguiente función lee el archivo con el NDVI correspondiente a un
↪ mes y a un año dados (si está disponible)

read_NDVI = function(MM,YYYY) {
  MM = str_pad(as.character(MM),2,"left",pad = "0")
  YY = substr(as.character(YYYY),3,4)
  if (as.numeric(YY)<=06) {
    ruta <-
↪ paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIFF/TI")
  } else if (as.numeric(YY)<=11) {
    ruta <-
↪ paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIF/TE")
  } else if (as.numeric(YY)<=21){
    ruta <-
↪ paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIFF/t")
  }else {
    ruta <-
↪ paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/COG/te")
  }

  if (file.exists(ruta)) {
    NDVI = rast(ruta)
  } else
    NDVI = NA
  return(NDVI)
}

# Los meses para los cuales no está disponible el archivo de NDVI:
year_month_missing_NDVI = c(
  "2003-01",
  "2003-04",
  "2017-02",
  "2018-11",
  "2020-11",
  "2021-12",
  "2022-03",
  "2022-12")

# Para cada observación para la que no está disponible el NDVI (porque
↪ la información de ese mes no está disponible), se obtiene el
↪ correspondiente al mismo mes del año anterior, si este está
↪ disponible, si no, el del año posterior:

missing_NDVI = full_grid |>
  filter(is.na(NDVI)) |>
```

```

mutate(year = year(date), month = month(date)) |>
group_by(year, month) |>
filter(paste(year, str_pad(as.character(month), 2, "left", pad =
  ↪ "0"), sep = "-") %in% year_month_missing_NDVI) |> # Se filtra
  ↪ porque también hay observaciones que tienen NA en el NDVI no
  ↪ porque no exista el archivo, si no lo mismo que en ocasiones
  ↪ anteriores, porques discrepancias entre los límites de los
  ↪ polígonos
nest() |>
mutate(NDVI_rast = map2(month, year-1, read_NDVI), # Se lee primero el
  ↪ del año anterior
  NDVI_rast =
    ↪ ifelse(is.na(unlist(NDVI_rast)), map2(month, year+1, read_NDVI), NDVI_rast),
    ↪ # Si no está disponible, se toma el del año posterior
  NDVI_nuevo = map2(NDVI_rast, data, ~terra::extract(.x, .y)[, 2])) |>
select(-NDVI_rast) |>
unnest(c(data, NDVI_nuevo)) |>
mutate(NDVI = NDVI_nuevo, .keep = "unused")

ind_modificados = is.na(full_grid$NDVI) &
  ↪ (paste(year(full_grid$date), str_pad(as.character(month(full_grid$date)), 2, "left",
  ↪ = "0"), sep = "-") %in% year_month_missing_NDVI) # Los elementos que
  ↪ han sido modificados

# Se asignan los valores imputados del NDVI:
full_grid[ind_modificados,]$NDVI = missing_NDVI$NDVI

# Resumen
datos %>% st_drop_geometry %>% skim(.data_name = "datos")

```

Se agrupan los niveles de uso de suelo

```

full_grid <- full_grid |>
  mutate(uso_suelo = fct_other(uso_suelo,
    keep =
      ↪ c("21", "22", "23", "24", "31", "32", "33"),
    other_level = "Otro"))

# save(full_grid, file = full_grid_meses_2022_processed.RData)

```

Se usará el modelo de regresión logística lasso final,

```

load("Private/all_models_test.RData")

model <- models %>% filter(model_name == "lr")
# model <- models %>% filter(model_name == "svm_linear")

```

```

# model <- models %>% filter(model_name=="rf")

rm(models) # Es un archivo muy pesado, lo eliminamos de la memoria

# Predicciones
pred_class = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid)
pred_probs = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid, type="prob")
pred = cbind(full_grid, pred_class, pred_probs)

# Se cargan los incendios producidos en el año 2022
incendios22 <-
  ↪ st_read(paste0("./data_raw/incendios_2000-2022/incendios_", 2022, ".shp"))
  ↪ %>%
    st_transform(st_crs(full_grid)) %>%
    mutate(date=ymd(fecha_inic))

```

Se muestra el gráfico con la estimación de la probabilidad de incendio el día 15 de cada mes en todos los puntos. Se añaden los incendios producidos en cada mes del año 2022

```

# Gráfico predicciones mes + Incendios producidos
ggplot(data = and) +
  geom_sf() +
  geom_sf(data = pred, aes(color=.pred_1), alpha=0.8, size = 1.5) +
  facet_wrap(~month(date, label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5, rev=T), limits=c(0,1)) +
  # scale_color_gradient(low="blue", high="red")+
  guides(alpha = "none") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank()) +
  geom_sf(data = incendios22 %>% st_centroid, color = "black", shape
  ↪ =24, size=1, fill = "red") +
  labs(title = "Probabilidad de incendio estimada el día 15 de cada mes
  ↪ de 2022",
        subtitle = paste0("Modelo: ", model$model_name),

```

```
color = "Probalidad\nde incendio\nestimada")
```

1.7. Caso de interés

Se va a usar el modelo para estudiar el incendio del 8 de septiembre de 2021 en Sierra Bermeja por ser de especial relevancia.

```
# Se carga la información del incendio
incendios21 <-
  ↪ st_read(paste0("./data_raw/incendios_2000-2022/incendios_",2021,".shp"))
  ↪ %>%
    st_transform(st_crs(datos)) %>%
    mutate(FECHA_INIC=ymd(FECHA_INIC))

incendio_estudio <- incendios21 %>% filter(month(FECHA_INIC)==9)
rm(incendios21)

# Mapa de Andalucía y de las provincias
and <- esp_get_ccaa(ccaa = "Andalucía") %>% st_transform(st_crs(datos))
prov <- esp_get_prov() %>% filter(nuts2.name=="Andalucía") %>%
  ↪ st_transform(st_crs(datos))

# Gráfico del incendio
g = prov %>%
  ggplot() +
  geom_sf() +
  geom_sf(data = incendio_estudio, color="red",fill=alpha("red",0.2))+
  theme_minimal()+
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())

# Ampliamos la zona del incendio
bbox = st_buffer(incendio_estudio,dist=10000) %>%
  st_bbox()

g1 = prov %>%
  ggplot() +
  geom_sf() +
  geom_sf(data = incendio_estudio, color="red",fill=alpha("red",0.2))+
  theme_minimal() +
  coord_sf(xlim=c(bbox$xmin,bbox$xmax),ylim=c(bbox$ymin,bbox$ymax))
```

```
# Gráfico final
gg <- ggarrange(g,g1)
annotate_figure(gg,
  top = text_grob("Caso de estudio: Incendio de Sierra
    ↪ Bermeja\n8 de septiembre de 2021",size = 14))
```

Se procede de forma similar a la sección anterior. Se crea una rejilla de puntos con una separación de 1km, en la zona que rodea al incendio. En cada punto se predecirá el riesgo de incendio el día de inicio del incendio, 15 y 30 días antes y 15, 30 y 45 días después.

```
# Se crea el grid
grid = st_make_grid(st_buffer(incendio_estudio,dist=10000),
  cellsize = c(1000,1000),
  what = "centers")[and]

# Visualización
g +
  geom_sf(data = grid,size=0.7) +
  coord_sf(xlim=c(bbox$xmin,bbox$xmax),ylim=c(bbox$ymin,bbox$ymax))

# Se le asocian las fechas respectivas
sample = tibble(date =
  ↪ rep(incendio_estudio$FECHA_INIC,length(grid)),geometry = grid) %>% #
  ↪ el día del incendio
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC+15,length(grid)),geometry
    ↪ = grid)) %>% # 15 días después
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC+30,length(grid)),geometry
    ↪ = grid)) %>% # el mes después
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC+45,length(grid)),geometry
    ↪ = grid)) %>% # 45 días después del incendio
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC-15,length(grid)),
    ↪ geometry = grid)) %>% # 15 días antes
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC-30,length(grid)),geometry
    ↪ = grid)) %>% # el mes antes

st_sf()
```

Se le asocian a cada registro todas las variables predictoras correspondientes.

```
source("scripts/strat/fun_asignar_variables - copia.R")
full_grid <- asignar_variables(sample)
```

```

# Se eliminan las observaciones con valores perdidos:
full_grid <- full_grid %>% drop_na()

# Se agrupan los niveles de uso de suelo
full_grid <- full_grid |>
  mutate(uso_suelo = fct_other(uso_suelo,
                              keep =
                                ↪ c("21","22","23","24","31","32","33"),
                              other_level= "Otro"))

full_grid %>% st_drop_geometry() %>% skim()

# save(full_grid, file =
  ↪ "salidas_intermedias/full_grid_incendio_0921_processed.RData")

```

Se usará el modelo de regresión logística lasso final para estimar la probabilidad de incendio en cada punto.

```

load("Private/all_models_test.RData")

model <- models %>% filter(model_name=="lr")
# model <- models %>% filter(model_name=="svm_rbf")
# model <- models %>% filter(model_name=="svm_linear")
# model <- models %>% filter(model_name=="rf")

rm(models) # Es un archivo muy pesado, lo eliminamos de la memoria

# Predicciones
pred_class = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid)
pred_probs = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid, type="prob")
pred = cbind(full_grid, pred_class, pred_probs)

```

Se muestra en un gráfico

```

g <- ggplot(data = and) +
  geom_sf() +
  geom_sf(data = pred, aes(color=.pred_1, alpha = .pred_1), size = 1.5) +
  facet_wrap(~date) +

```

```

scale_color_gradientn(colours = rainbow(5,rev=T),limits=c(0,1)) +
# scale_color_gradient(low="blue", high="red")+
labs(title="Incendio de Sierra Bermeja",
      subtitle = paste0("Model: ",model$model_name)) +
guides(alpha = "none") +
theme_minimal() +
theme(axis.text.x=element_blank(),
      axis.ticks.x=element_blank(),
      axis.text.y=element_blank(),
      axis.ticks.y=element_blank(),
      panel.grid.major = element_blank(),
      panel.grid.minor = element_blank()) +
geom_sf(data = incendio_estudio, fill="transparent",col="red") +
labs(color = "Probabilidad\nestimada de\nincendio") +
coord_sf(xlim=c(bbox$xmin,bbox$xmax),ylim=c(bbox$ymin,bbox$ymax))

```

g

Se usa la función definida para asignar las variables explicativas a la muestra generada:

```

# Se carga la muestra generada en el paso anterior:
load("salidas_intermedias/sample_strat_2024-04-26.RData")

# Se eliminan las observaciones que no tienen fecha pues se pueden usar
↪ para el estudio
sample <- na.omit(sample)

# Se aplica la función a la muestra
dataset <- asignar_variables(sample)

# Se almacenan los resultados
save(dataset,
      file = paste0("salidas_intermedias/dataset_strat_completo",
                    Sys.Date(), ".RData"))

```

1.8. Depuración de la muestra

En la propia función usada para generar la muestra ya se ajustaron los tipos de las variables y se codificaron adecuadamente las variables *WD10M* y *orientacion*. A continuación se estudian los casos faltantes y finalmente se decide eliminarlos.

```

# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos
library(sf) # Vector data

```



```

library(terra) # Raster data
library(mapSpain) # Polígonos de regiones de España
library(magrittr) # Operador %<>%
library(skimr) # Resumen de datos

# Carga de los datos -----
# Se carga la muestra con todas las variables construida anteriormente
load("salidas_intermedias/dataset_strat_completo2024-04-26.RData")

# Codificación variable fire: -----
datos <- dataset |>
  mutate(fire = as.factor(fire))

# Análisis de valores perdidos: -----
datos %>% skimr()
dataset %>% apply(1,anyNA) %>% sum() # 200 registros con valores
  ↪ perdidos

# Se observan:
# 8 nas en uso_suelo
# 32 nas en pendiente
# 36 nas en orientacion
# 32 nas en curvatura
# 85 nas en doblacion y en dist_poblacion
# 85 nas en NDVI

datos1 = datos %>% drop_na()

# Valores perdidos en variables topográficas -----
Andalucia <- esp_get_ccaa(ccaa = "Andalucía") # Se carga el mapa de
  ↪ Andalucía
andalucia_proj <- st_transform(Andalucia,st_crs(dataset)) # Se proyecta
  ↪ al sistema de referencia de los datos

# Mapa de valores perdidos en variables topográficas:
plot(st_geometry(andalucia_proj),reset=F)
datos |>
  filter(is.na(pendiente) | is.na(orientacion) | is.na(curvatura)) |>
  st_geometry() |>
  plot(pch=16,col="red",add=T) # Se encuentran en los límites de
  ↪ Andalucía

datos |>
  st_drop_geometry() |>
  filter(is.na(pendiente) | is.na(orientacion) | is.na(curvatura)) |>
  count() #53 registros con algún valor perdido entre las variables
  ↪ topográficas

```

```

# Valores perdidos en variables demográficas -----
# Se observa que los valores perdidos se deben a que los datos no están
  ↪ disponibles en el conjunto de datos disponible en el INE
datos |>
  st_drop_geometry() |>
  filter(is.na(poblacion)) |>
  mutate(Año = year(date)) |>
  select(Año,municipio,cod_municipio)

# Ejemplo:
pob =
  ↪ read_csv2("data_raw/antropologicas/Población/poblacion_municipios.txt")[,c(1:5)]
  ↪
pob |> filter(CODIGO_INE3 == "18077") # Datos no disponibles

datos |>
  st_drop_geometry() |>
  filter(is.na(poblacion)) |>
  count() # 85 registros con valores perdidos en las variables
  ↪ demográficas

# Valores perdidos en uso_suelo -----
dataset |> filter(is.na(uso_suelo)) %>% count() # 8 registros con
  ↪ valores perdidos en la variable uso_suelo

dataset |> filter(is.na(uso_suelo)) |> st_geometry() |>
  ↪ plot(pch=16,col="red",add=T)
# De nuevo se observa que se encuentran en los límites de Andalucía con
  ↪ la costa

# Valores perdidos en NDVI -----
# Se muestran en el mapa
plot(st_geometry(andalucia_proj),reset=F)
dataset |> filter(is.na(NDVI)) |> st_geometry() |>
  ↪ plot(pch=16,col="red",add=T)

# Gráfico de NDVI medio cada mes
NDVI_mes = datos |>
  st_drop_geometry() |>
  mutate(mes = month(date),
         año = year(date)) |>
  group_by(año,mes) |>
  summarise(NDVI_mes = mean(na.omit(NDVI))) |>
  ungroup() |>

```

```
mutate(date = dmy(paste(01,mes,año,sep="/")))
```

NDVI_mes |>

```
ggplot(aes(x=date,y=NDVI_mes)) +
  geom_line()+
  scale_x_date(date_breaks = "6 month",date_labels = "%y%b")+
  theme(axis.text.x = element_text(angle = 90))
```

2008 tiene un NDVI especialmente bajo, puede deberse a numerosos
↪ factores:
- Que efectivamente sea un año especialmente seco
- Las características de la muestra seleccionada ese año
- Errores de medición
- ...

La mayor parte de los valores perdidos en la variable uso_suelo son
↪ debidos a que el archivo tiff para ese mes no está disponible en la
↪ REDIAM. Los meses de los que no se dispone del ráster NDVI son:
↪ "2003-01", "2003-04", "2017-02", "2018-11", "2020-11", "2021-12",
↪ "2022-03" y "2022-12".

Eliminación registros con valores perdidos -----
Tras explorar otras opciones finalmente se opta por eliminar los
↪ registros
que contienen valroes perdidos:
 datos = datos %>% drop_na()

Almacenamiento del conjunto de datos depurados -----
Se guarda el conjunto de datos depurados
 save(datos,
 file = paste0("salidas_intermedias/datos_strat_depurados_geom",
 Sys.Date(), ".RData"))

1.9. Análisis exploratorio

```
# Librerías -----  

# Se cargan las librerías que se usarán en esta sección  

library(tidyverse) # Manipulación de datos  

library(sf) # Vector data  

library(terra) # Raster data  

library(mapSpain) # Polígonos de regiones de España  

library(magrittr) # Operador %<>%  

library(skimr) # Resumen de datos  

library(corrplot) # Gráfico de correlaciones  

library(GGally) # Coordenadas paralelas
```

```
library(ggpubr) # Función ggarrange

# Carga de los datos -----
load("salidas_intermedias/datos_strat_depurados_geom_2024-05-03.RData")

# Resumen numérico -----
datos %>% st_drop_geometry %>% skim(.data_name = "datos")
```

1.9.1. Variable objetivo

```
# Distribución temporal -----
# Mensual:
g_mes <- datos %>%
  st_drop_geometry() %>%
  # filter(fire==1) %>%
  count(month(date,label=T),fire) %>%
  rename("mes" = "month(date, label = T)") %>%
  ggplot(aes(x = mes,y = n,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  # theme(axis.text.x = element_text(angle = 90)) +
  scale_fill_hue(direction = -1) +
  theme_minimal() +
  xlab("Mes") +
  ylab("Número de observaciones")

g_mes

# Anual
g_year <- datos %>%
  st_drop_geometry() %>%
  # filter(fire==1) %>%
  count(year(date),fire) %>%
  rename("año" = "year(date)") %>%
  ggplot(aes(x = año,y = n,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_x_continuous(breaks=2002:2022) +
  geom_smooth(se=F,aes(color=fire),alpha=0.1) +
  scale_color_manual(values=c("darkblue","darkred")) +
  scale_fill_hue(direction = -1) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust=1)) +
  xlab("Año") +
  ylab("Número de observaciones")

g_year
```

```

# En 2007 no se han generado observaciones positivas
# Causa: En el shapefile que contiene los incendios producidos en 2007
↳ solo hay 4 observaciones y ninguna tenía la fecha, por lo que estas
↳ no han podido utilizarse

# Valores muy bajos en 2008 y 2010, revisar
# 2010: correcto, en el archivo con los polígonos de incendios en 2010
↳ solo hay 26 observaciones
# 2008: en el archivo relativo a ese año hay 37 observaciones, pero 11
↳ de ellas no tienen la fecha de inicio, por lo que no se han podido
↳ utilizar

# Día de la semana
g_dia <- datos %>%
  st_drop_geometry() %>%
  # filter(fire==1) %>%
  count(weekdays(date),fire) %>%
  rename("dia" = "weekdays(date)") %>%
  ggplot(aes(x = dia,y = n,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_x_discrete(limits=c("lunes", "martes", "miércoles", "jueves",
  ↳ "viernes", "sábado", "domingo")) +
  theme(axis.text.x = element_text(angle = 45, vjust = 0.5, hjust=0.5)) +
# geom_smooth(se=F) +
  scale_fill_hue(direction = -1) +
  theme_minimal() +
  xlab("Día") +
  ylab("Número de observaciones")
g_dia

# Para mostrar los tres gráficos juntos
ggarrange(g_dia,g_mes,g_year,ncol=1,common.legend = T,legend = "bottom")

# Distribución temporal -----
# Se cargan los polígonos de las provincias
and <- esp_get_ccaa(ccaa = "Andalucía") %>% st_transform(st_crs(datos))
prov <- esp_get_prov() %>% filter(nuts2.name=="Andalucía") %>%
↳ st_transform(st_crs(datos))

# Casos positivos
g1 = ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos %>% filter(fire==1),size = 1, alpha =
  ↳ 0.4,col="red")+
  ggtitle("Distribución espacial de casos positivos") +
  theme_minimal()

```

```
# Casos negativos
g0 = ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos %>% filter(fire==0), size = 1, alpha =
    ↪ 0.4, col="blue") +
  ggtitle("Distribución espacial de casos negativos") +
  theme_minimal()

# Ambos gráficos juntos:
ggarrange(g1, g0, nrow=2)
```

1.9.2. Análisis univariantes

T2M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=T2M), size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date, label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5, rev=T)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de T2M por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

Las temperaturas más elevadas se encuentran en el interior.

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date, label=T), fire) %>%
  summarize(AVG_T2M = mean(T2M),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes, y=AVG_T2M, fill=fire)) +
  geom_col(position="dodge", alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
# + theme(axis.text.x = element_text(angle = 45, vjust = 0.5,
  ↪ hjust=0.5))
```

En prácticamente todos los meses, la media de temperaturas en las observaciones positivas es mayor que en las observaciones negativas. Las temperaturas son más altas en los meses de verano, como cabía esperar.

RH2M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=RH2M),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=F)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de RH2M por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

La humedad del aire es mayor en las de costa. Las zonas más secas se encuentran en las zonas de interior del norte de Andalucía.

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_RH2M = mean(RH2M),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_RH2M,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
# + theme(axis.text.x = element_text(angle = 45, vjust = 0.5,
  ↪ hjust=0.5))
```

En prácticamente todos los meses, la humedad del aire media entre las observaciones positivas es menor que en las observaciones negativas. La humedad del aire disminuye significativamente en verano.

GWETTOP

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=GWETTOP),size = 1, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=F)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de GWETTOP por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

Las zonas con mayor humedad superficial de suelo son las que se encuentran en la costa mediterránea. Las zonas con un suelo más seco son las que se encuentran al norte de la cuenca el Guadalquivir, destacando la provincia de Huelva (hay que tener en cuenta que también es una zona en la que hay muchos incendios, la mayoría de los cuales se produce en verano, por lo que hay una gran concentración de observaciones durante el periodo estival, lo que podría influir en el hecho de que se observen tantas observaciones con valores tan bajos de la humedad superficial de suelo).

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_GWETTOP = mean(GWETTOP),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_GWETTOP,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
```

En general, la humedad superficial de suelo media entre los casos positivos es inferior que entre los casos negativos. Esto es especialmente evidente entre los meses de primavera y otoño. En los meses de invierno esto no está tan claro, incluso parece revertirse la tendencia.

WS10M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos,
    ↪ aes(color=WS10M,alpha=WS10M,size=as.numeric(ifelse(WS10M<7.5,1,1.2))))
    ↪ +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
```



```
facet_wrap(~month(date,label=TRUE))+
# scale_color_gradient(low="blue", high="red")+
ggtitle("Distribución espacial de WS10M por mes") +
theme_minimal() +
theme(axis.text.x=element_blank(),
      axis.ticks.x=element_blank(),
      axis.text.y=element_blank(),
      axis.ticks.y=element_blank(),
      panel.grid.major = element_blank(),
      panel.grid.minor = element_blank()) +
guides(size="none",alpha="none")
```

Los valores más elevados de la velocidad del viento a 10m de altura se dan en las zonas costeras.

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_WS10M = mean(WS10M),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_WS10M,fill=fire)) +
  geom_col(position="dodge",alpha=0.8)+
  scale_fill_hue(direction = -1) +
  theme_minimal()
```

En todos los meses, los valores medios de la velocidad del viento a 10m sobre la superficie son significativamente mayores en las observaciones positivas.

WD10M

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=WD10M),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE))+
  # scale_color_stepsn(colours = rainbow(8,rev=T)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de WD10M por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank()) +
  guides(color = guide_legend(override.aes = list(size = 5))) +
  scale_color_viridis_d(option="turbo")
```

```

# Quisiera tener la dirección mayoritaria por mes y si hay incendio o no
↪
mode <- function(x) { names(which.max(table(x))) }

datos_mode_WD10M = datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(mode_WD10M = mode(WD10M))

tibble(mes = datos_mode_WD10M[datos_mode_WD10M$fire==1,1],
       fire1 = datos_mode_WD10M[datos_mode_WD10M$fire==1,3],
       fire0 = datos_mode_WD10M[datos_mode_WD10M$fire==0,3])

# No parece aportar ninguna información relevante

```

PRECTOTCORR

```

ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos,
    ↪ aes(color=PRECTOTCORR,size=PRECTOTCORR,alpha=PRECTOTCORR)) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=F)) +
  guides(size="none") +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de PRECTOTCORR por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank()) +
  guides(alpha="none")

```

En la gran mayoría de las observaciones no se han observado precipitaciones. Se observan algunos valores positivos de precipitaciones distribuidos por el territorio andaluz, alcanzándose los máximos en observaciones localizadas en las cordilleras béticas.

```

datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_PRECTOTCORR = mean(PRECTOTCORR),
           Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_PRECTOTCORR,fill=fire)) +

```

```
geom_col(position="dodge",alpha=0.8) +
scale_fill_hue(direction = -1) +
theme_minimal()
```

Se observa una clara diferencia en la media mensual de precipitaciones en ambas clases en todos los meses, siendo mucho mayores entre las observaciones negativas. En los meses de verano esto sigue siendo cierto, si bien las diferencias se suavizan significativamente, ya que en ambos clases las precipitaciones son reducidas.

NDVI

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=NDVI),size = 1.2, alpha = 0.6) +
  facet_wrap(~month(date,label=TRUE)) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de NDVI por mes") +
  theme_minimal() +
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),
        axis.ticks.y=element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank())
```

Los valores más elevados del NDVI se encuentran en el norte de la comunidad (Sierra Morena y Sierra de Aracena) y en la zona sur-centro. Los valores son especialmente elevados en la Sierra de Grazalema y en las marismas del Guadalquivir y especialmente bajos en el este de la comunidad (Almería).

```
datos %>%
  st_drop_geometry() %>%
  group_by(month(date,label=T),fire) %>%
  summarize(AVG_NDVI = mean(NDVI),
            Mes = `month(date, label = T)` ) %>%
  ggplot(aes(x=Mes,y=AVG_NDVI,fill=fire)) +
  geom_col(position="dodge",alpha=0.8) +
  scale_fill_hue(direction = -1) +
  theme_minimal()
# theme(axis.text.x = element_text(angle = 45, vjust = 0.5,
  ↪ hjust=0.5))
```

El valor del NDVI disminuye en los meses de verano y alcanza su máximo en los meses de invierno. No se observa claramente una relación entre el NDVI y la clase de la observación en la muestra.

poblacion

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=poblacion,size =
    ↪ poblacion,alpha=poblacion/median(poblacion))) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de poblacion") +
  theme_minimal()

by(datos$poblacion,datos$fire,summary)
```

En la gran mayoría del territorio se observan niveles de población inferiores a 20.000 habitantes por municipio. Destacan las capitales de provincia por tener valores significativamente más elevados.

dens_poblacion

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=dens_poblacion, size= dens_poblacion,
    ↪ alpha=dens_poblacion)) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  # scale_color_gradient(low="blue", high="red")+
  ggtitle("Distribución espacial de dens_poblacion") +
  theme_minimal()

by(datos$dens_poblacion,datos$fire,summary)
```

Se puede observar una distribución espacial similar a la cantidad de población. Se observa una mayor densidad de población en las zonas de costa y en las capitales de provincia.

pendiente

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=pendiente, size= pendiente,
    ↪ alpha=pendiente)) +
  scale_color_gradientn(colours = rainbow(5,rev=T)) +
```

```
guides(size="none",alpha="none") +
ggtitle("Distribución espacial de pendiente") +
theme_minimal()
```

elevacion

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=elevacion, size= elevacion,
    ↪ alpha=elevacion)) +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de elevacion") +
  theme_minimal()
```

curvatura

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=curvatura, alpha=curvatura)) +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de curvatura") +
  theme_minimal()
```

dist_carretera

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=dist_carretera, alpha=dist_carretera))
  ↪ +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de dist_carretera") +
  theme_minimal()
```

dist_electr

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_electr, alpha=dist_electr)) +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_electr") +  
  theme_minimal()
```

dist_camino

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_camino, alpha=dist_camino)) +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_camino") +  
  theme_minimal()
```

dist_sendero

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_sendero, alpha=dist_sendero)) +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_sendero") +  
  theme_minimal()
```

dist_poblacion

```
ggplot(data = prov) +  
  geom_sf() +  
  geom_sf(data = datos, aes(color=dist_poblacion, alpha=dist_poblacion))  
  ↪ +  
    scale_color_gradientn(colours = rainbow(5,rev=T)) +  
  guides(size="none",alpha="none") +  
  ggtitle("Distribución espacial de dist_poblacion") +  
  theme_minimal()
```

dist_ferrocarril

```
ggplot(data = prov) +
  geom_sf() +
  geom_sf(data = datos, aes(color=dist_ferrocarril,
    ↪ alpha=dist_ferrocarril)) +
    scale_color_gradientn(colours = rainbow(5,rev=T)) +
  guides(size="none",alpha="none") +
  ggtitle("Distribución espacial de dist_ferrocarril") +
  theme_minimal()
```

1.9.3. Análisis multivariantes

Variables numéricas

```
datos_numeric = datos %>%
  select(where(is.numeric)) %>%
  st_drop_geometry()

# Correlaciones -----
R = cor(datos_numeric)
corrplot(R,method = "ellipse",type = "lower")
summary(R-diag(diag(R)))
# Las variables más correlacionadas en la muestra son T2M con RH2M
↪ (negativamente, -0.71), T2M con GWETTOP (negativamente, -0.69) y
↪ GWETTOP con R2HM (positivamente, 0.68). Tiene sentido que la humedad
↪ del aire a dos metros esté correlacionada positivamente con la
↪ humedad del suelo y que ambas estén negativamente correlacionadas
↪ con la temperatura del aire. También están correladas la población
↪ con la densidad de población (positivamente,0.63).

# Gráfico de coordenadas paralelas -----
datos |>
  select(fire,where(is.numeric)) |>
  ggparcoord(columns=2:19,alphaLines=0.1,groupColumn = "fire") +
  xlab('') +
  ylab('') +
  scale_x_discrete(labels=colnames(datos_numeric)) +
  scale_color_hue(direction = -1) +
  # guides(color = "none")+
  theme_minimal() +
  ggtitle("Tipificación a normal estándar (por defecto)") +
  theme(plot.title = element_text(size = 9),
    axis.text.x = element_text(angle = 90))
```

```

# Boxplots -----
boxplots <- map(names(datos_numeric), ~ ggplot(datos, aes(x = fire, y =
  ↪ .data[[.x]], fill=fire)) +
      geom_boxplot() +
      scale_fill_hue(direction = -1) +
      guides(fill="none") +
      labs(title = paste(.x, "~ fire")))
ggarrange(plotlist = boxplots, ncol=6, nrow=3)

# PCA -----
pca <- princomp(datos_numeric, cor=T)
summary(pca)
# Se necesitan al menos 11 componentes principales para explicar el 80%
  ↪ de la variabilidad de las 18 variables numéricas de la muestra
  ↪ (tipificadas) y al menos 14 para explicar el 90%. Esto refleja, la
  ↪ complejidad del conjunto de datos.

```

Variables categóricas

```

datos_categ <- datos %>%
  select(WD10M, orientacion, enp, uso_suelo) %>%
  st_drop_geometry()

# Histogramas -----
histogramas <- map(names(datos_categ),
  ~ ggplot(datos, aes(x = .data[[.x]],
    fill = fire)) +
      geom_bar(position = "dodge", alpha = 0.8) +
      scale_fill_hue(direction = - 1) +
      theme_minimal() +
      labs(title = .x) +
      theme(axis.text.x = element_text(size=7)))

ggarrange(plotlist = histogramas, ncol = 2, nrow =
  ↪ ceiling(length(histogramas)/2))

```

1.10. Modelos

```

# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos

```



```

library(sf) # Vector data
library(tidymodels) # Ecosistema para la construcción de modelos
library(akima) # Función interp
library(magrittr) # Operador %>%
library(ggpubr) # Función ggarrange
library(knitr) # Función kable

# Carga de datos -----
load("salidas_intermedias/datos_strat_depurados_geom_2024-05-03.RData")

# Agrupación clases uso_suelo -----
# Nos quedamos con los 7 niveles del factor más frecuentes (clases 2 y
  ↪ 3)
datos <- datos |>
  mutate(uso_suelo = fct_lump(uso_suelo,
                              n = 7,
                              other_level= "Otro"))

# Funciones para la evaluación de modelos -----
# Función para obtener las medidas de rendimiento de los modelos a
  ↪ partir de un objeto predict
get_metrics <- function(pred) {
  list(
    res = tibble(
      roc_auc = pred |> roc_auc(truth = fire, .pred_0) |>
        ↪ pull(.estimate),
      accuracy = pred |> accuracy(truth = fire, .pred_class) |>
        ↪ pull(.estimate),
      recall = pred |> sensitivity(truth = fire,
        ↪ .pred_class,event_level="second") |> pull(.estimate),
      specificity = pred |> spec(truth = fire,
        ↪ .pred_class,event_level="second") |> pull(.estimate),
      precision = pred |> precision(truth = fire,
        ↪ .pred_class,event_level="second") |> pull(.estimate)),
    conf_mat = pred |> conf_mat(truth = fire, .pred_class))
}

# Función para mostrar gráficamente los resultados del tuning de un
  ↪ modelo con dos parámetros
tuning_plot = function(mod_res) {
  datos_metrics = mod_res %>%
    collect_metrics()

  plots = list()

  for (metric in unique(datos_metrics$.metric)) {

```

```
datos = datos_metrics %>%
  filter(.metric==metric)

# Interpolan los datos faltantes
datos_interp <- interp(datos[[1]], datos[[2]], datos$mean)

# Crear un nuevo dataframe con los datos interpolados
datos_interp_df <- data.frame(
  expand.grid(x = datos_interp$x, y = datos_interp$y), z =
    ↪ as.vector(datos_interp$z))

# Crear el gráfico de mapa de calor con interpolación
p = ggplot(datos_interp_df, aes(x = x, y = y, fill = z)) +
  geom_tile() +
  scale_fill_viridis_c(option = "turbo", name = NULL, na.value =
    ↪ "transparent")+
  labs(title = "",
        x = colnames(datos)[1],
        y = colnames(datos)[2],
        fill = metric) +
  theme_minimal()

plots[[metric]] = p
}
ggarrange(plotlist = plots,
  labels=c("Accuracy", "Specificity", "ROC-AUC", "Recall"),
  align = "hv")
}
```

1.10.1. Partición temporal entrenamiento-validación-test

```
set.seed(123)

splits = initial_validation_time_split(datos,
  prop=c(0.6,0.2))

training <- training(splits) %>% st_drop_geometry()
val_set <- validation_set(splits) %>% st_drop_geometry()
test <- testing(splits) %>% st_drop_geometry()
```

1.10.2. Regresión logística con penalización

```

# 1º Definimos el modelo:
lr_mod <-
  logistic_reg(penalty = tune(), mixture = tune()) %>%
  set_engine("glmnet")

# 2º Creamos la receta
lr_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  # step_holiday(date, holidays = holidays) %>%
  step_rm(date, cod_municipio, municipio) %>% # Se eliminan variables
  → identificadoras
  step_dummy(all_nominal_predictors()) %>% # Se crean variables dummy
  → para los factores
  step_lincomb() %>% # Elimina variables con dependencia lineal exacta
  step_corr() %>% # Elimina variables con correlación superior a 0.9
  step_zv(all_predictors()) %>% # Eliminar variables con varianza nula
  step_normalize(all_predictors()) # Se normalizan todos los predictores

# 3º Creamos el workflow
lr_workflow <-
  workflow() %>%
  add_model(lr_mod) %>%
  add_recipe(lr_recipe)

# 4º Creamos el grid para los parámetros
lr_reg_grid <- expand_grid(penalty = 10^seq(-4, -1, length.out = 10),
                          mixture = seq(0, 1, length.out = 10))

# 5º Ajustamos el modelo
lr_res <-
  lr_workflow %>%
  tune_grid(val_set,
            grid = lr_reg_grid,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# 6º Evaluación de modelos
tuning_plot(lr_res)

lr_res |>
  collect_metrics() |>
  group_by(.metric) |>
  mutate(.metric = ifelse(.metric == "recall", "spec",
                          ifelse(.metric == "spec", "recall",
                                .metric))) |>
  summarise(max = max(mean), min = min(mean))

```

```

# 7º Selección del mejor modelo
lr_best <-
  lr_res %>%
  select_best(metric="accuracy")
lr_best

# Extraer coeficientes
lr_workflow %>%
  finalize_workflow(lr_best) %>%
  fit(training) %>%
  extract_fit_parsnip() %>%
  tidy() %>%
  print(n=100)

```

1.10.3. Regresión logística con penalización + PCA

```

# 1º Creamos el modelo
lr_pca_mod <-
  logistic_reg(penalty = tune(), mixture = tune()) %>%
  set_engine("glmnet")

# 2º Creamos la receta
lr_pca_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  # step_holiday(date, holidays = holidays) %>%
  step_rm(date, cod_municipio, municipio) %>% # Se eliminan variables
  ↪ identificadoras
  step_dummy(all_nominal_predictors()) %>% # Se crean variables dummy
  ↪ para los factores
  step_lincomb() %>% # Elimina variables con dependencia lineal exacta
  step_corr() %>% # Elimina variables con correlación superior a 0.9
  step_zv(all_predictors()) %>% # Eliminar variables con varianza nula
  step_normalize(all_predictors()) %>% # Se normalizan todos los
  ↪ predictores
  step_pca(all_numeric_predictors(), num_comp = tune())

# 3º Creamos el workflow
lr_pca_workflow <-
  workflow() %>%
  add_model(lr_pca_mod) %>%
  add_recipe(lr_pca_recipe)

```

```

# 4º Creamos el grid para los parámetros
lr_pca_reg_grid <- expand_grid(penalty = 10^seq(-4, -1, length.out = 10),
                              mixture = seq(0,1,length.out=10),
                              num_comp = c(20,25,30,35,40,45,50))

# 5º Ajustamos el modelo
lr_pca_res <-
  lr_pca_workflow %>%
  tune_grid(val_set,
            grid = lr_pca_reg_grid,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# 6º Evaluación modelos
lr_pca_tuning = lr_pca_res |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))

# 7º Selección del mejor modelo
lr_pca_best <-
  lr_pca_res %>%
  select_best(metric="accuracy")
lr_pca_best

```

1.10.4. Árboles de decisión

```

# 1º Creamos el modelo
dt_mod <-
  decision_tree(cost_complexity = tune()) %>%
  set_engine("rpart") %>%
  set_mode("classification")

# 2º Creamos la receta
dt_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date,features = c("dow", "month")) %>%
  # step_holiday(date)%>%
  step_rm(date, cod_municipio, municipio)

# 3º Creamos el workflow
dt_workflow <-
  workflow() %>%
  add_model(dt_mod) %>%

```

```

add_recipe(dt_recipe)

# 4º Se ajusta el modelo
set.seed(345)
dt_res <-
  dt_workflow %>%
  tune_grid(val_set,
            grid = 10,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# 5º Se evalúan los modelos obtenidos
dt_res |>
  collect_metrics() |>
  group_by(.metric)|>
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) |>
  summarise(max = max(mean),min=min(mean))

# Gráfico del ajuste
dt_res %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) |>
  ggplot(aes(x = cost_complexity, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  scale_x_log10(labels = scales::label_number())+
  theme_minimal()

# 6º Selección del mejor modelo
dt_best <- dt_res |>
  select_best(metric = "accuracy")
dt_best

```

1.10.5. Bosques aleatorios

```

# Detectar el número de núcleos para trabajar en paralelo
cores <- parallel::detectCores()
cores

# Construimos el modelo, especificando el número de núcleos a usar en la
↪ computación en paralelo de forma que la computación sea más
↪ eficiente

```

```

# ETAPA 1: fijado mtry=4, se ajusta min_n
# -----

# 1º Construir el modelo
rf_mod1 <-
  rand_forest(mtry = 4, min_n = tune(), trees = 1000) %>%
  set_engine("ranger", num.threads = cores) %>%
  set_mode("classification")

# 2º Construir la receta con el preprocesamiento
rf_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date, features = c("dow", "month")) %>%
  # step_holiday(date) %>%
  step_rm(date, cod_municipio, municipio)
# No normalizamos en este caso pues no es necesario

# 3º Ensamblar todo con workflow
rf_workflow1 <-
  workflow() %>%
  add_model(rf_mod1) %>%
  add_recipe(rf_recipe)

# 4º Train and tune
set.seed(345)

rf_res1 <-
  rf_workflow1 %>%
  tune_grid(val_set,
            grid = expand_grid(min_n = seq(1000, 2500, 100)),
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# Resultados del tuning

rf_tuning1 <- rf_res1 |>
  collect_metrics() |>
  group_by(.metric) |>
  summarise(max = max(mean), min = min(mean))

rf_tuning1

# plot

rf_plot1 <-
  rf_res1 %>%

```

```
collect_metrics() %>%
mutate(.metric = ifelse(.metric == "recall","spec",
                        ifelse(.metric == "spec","recall",
                              .metric))) %>%

ggplot(aes(x = min_n, y = mean,col=.metric)) +
geom_point() +
geom_line() +
ylab("") +
theme_minimal()+
labs(title = "Etapa 1\nFijado mtry = 4, se ajusta min_n")

# Mejor modelo
rf_best1 <-
  rf_res1 %>%
  select_best(metric = "spec")

rf_best1

rf_metrics1 <- rf_res1 |>
  collect_predictions(parameters = rf_best1) |>
  get_metrics()

rf_metrics1

# ETAPA 2: fijado min_n de la etapa anterior, se ajusta mtry
# -----

# 1º Se construye el modelo
rf_mod2 <-
  rand_forest(mtry = tune(), min_n = rf_best1$min_n, trees = 1000) %>%
  set_engine("ranger", num.threads = cores) %>%
  set_mode("classification")

# 2º Se usa la misma receta que antes

# 3º Ensamblar todo con workflow
rf_workflow2 <-
  workflow() %>%
  add_model(rf_mod2) %>%
  add_recipe(rf_recipe)

# 4º Train and tune
set.seed(345)

rf_res2 <-
```



```

rf_workflow2 %>%
  tune_grid(val_set,
            grid = expand_grid(mtry = 1:10),
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# Resultados del tuning

rf_tuning2 <- rf_res2 |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))

rf_tuning2

#plot
rf_plot2 <-
  rf_res2 %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) %>%
  ggplot(aes(x = mtry, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  theme_minimal()+
  labs(title = paste0("Etapa 2\nFijado min_n = ", rf_best1$min_n, " se
    ↪ ajusta mtry"))

# Mejor modelo
rf_best2 <-
  rf_res2 %>%
  select_best(metric = "spec")
rf_best2

rf_metrics2 <- rf_res2 |>
  collect_predictions(parameters = rf_best2) |>
  get_metrics()

rf_metrics2

# -----

# Plots

```

```
ggarrange(rf_plot1,rf_plot2,nrow=1,common.legend = T,legend = "bottom")
```

1.10.6. k-Nearest Neighbours

```
# 1º Definimos el modelo:
knn_mod <-
  nearest_neighbor(neighbors = tune()) %>%
  set_engine("kknn") %>%
  set_mode("classification")

# 2º Creamos la receta
knn_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date,features = c("dow","month")) %>%
  # step_holiday(date, holidays = holidays) %>%
  step_rm(date,cod_municipio,municipio) %>% # Se eliminan variables
  ↪ identificadoras
  step_dummy(all_nominal_predictors()) %>% # Se crean variables dummy
  ↪ para los factores
  step_lincomb() %>% # Elimina variables con dependencia lineal exacta
  step_corr() %>% # Elimina variables con correlación superior a 0.9
  step_zv(all_predictors()) %>% # Eliminar variables con varianza nula
  step_normalize(all_predictors()) # Se normalizan todos los predictores

# 3º Creamos el workflow
knn_workflow <-
  workflow() %>%
  add_model(knn_mod) %>%
  add_recipe(knn_recipe)

# 4º Train and tune
set.seed(345)
knn_res <-
  knn_workflow %>%
  # fit(training)
  tune_grid(val_set,
            grid = expand_grid(neighbors = c(1,10,25,seq(25,400,25))),
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy,roc_auc,recall,spec))

# 5º Evaluación de los modelos
knn_res |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))
```

```

knn_res %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) %>%
  # filter(.metric == "accuracy") %>%
  ggplot(aes(x = neighbors, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  theme_minimal()

# 6º Selección del mejor modelo
knn_best <- knn_res |>
  select_best(metric = "accuracy")
knn_best

```

1.10.7. SVM lineal

```

# 1º Construir el modelo
svm_mod <-
  svm_linear(cost = tune()) %>%
  set_engine("kernlab") %>%
  set_mode("classification")

# 2º Construir la receta con el preprocesamiento
svm_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date,features = c("dow", "month")) %>%
  step_rm(date, cod_municipio, municipio) %>%
  step_dummy(all_nominal_predictors()) %>%
  step_zv(all_predictors()) %>%
  step_normalize(all_predictors())

# 3º Ensamblar todo con workflow
svm_workflow <-
  workflow() %>%
  add_model(svm_mod) %>%
  add_recipe(svm_recipe)

# 4º Train and tune
set.seed(345)
svm_res <-
  svm_workflow %>%

```

```

tune_grid(val_set,
          grid = 15,
          control = control_grid(save_pred = TRUE),
          metrics = metric_set(accuracy,roc_auc,recall,spec))

# 5º Evaluación de resultados del tuning
svm_res |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean),min=min(mean))

svm_plot <-
  svm_res %>%
  collect_metrics() %>%
  mutate(.metric = ifelse(.metric == "recall","spec",
                          ifelse(.metric == "spec","recall",
                                .metric))) %>%
  # filter(.metric == "accuracy") %>%
  ggplot(aes(x = cost, y = mean,col=.metric)) +
  geom_point() +
  geom_line() +
  ylab("") +
  theme_minimal()
svm_plot

# 6º Selección del mejor modelo
svm_best <-
  svm_res %>%
  select_best(metric="accuracy")
svm_best

```

1.10.8. SVM radial

```

# 1º Construir el modelo
svm_rbf_mod <-
  svm_rbf(cost = tune(),rbf_sigma = tune()) %>%
  set_engine("kernlab") %>%
  set_mode("classification")

# 2º Construir la receta con el preprocesamiento
svm_rbf_recipe <-
  recipe(fire ~ ., data = training) %>%
  step_date(date,features = c("dow", "month")) %>%
  step_rm(date, cod_municipio, municipio) %>%
  step_dummy(all_nominal_predictors()) %>%

```

```

step_lincomb() %>% # Elimina variables con dependencia lineal exacta
step_corr() %>% # Elimina variables con correlación superior a 0.9
step_zv(all_predictors()) %>%
step_normalize(all_predictors())

# 3º Ensamblar todo con workflow
svm_rbf_workflow <-
  workflow() %>%
  add_model(svm_rbf_mod) %>%
  add_recipe(svm_rbf_recipe)

# 4º Train and tune
set.seed(345)
svm_rbf_res <-
  svm_rbf_workflow %>%
  tune_grid(val_set,
            grid = 8,
            control = control_grid(save_pred = TRUE),
            metrics = metric_set(accuracy, roc_auc, recall, spec))

# 5º Evaluación de resultados del tuning
svm_rbf_res |>
  collect_metrics() |>
  group_by(.metric)|>
  summarise(max = max(mean), min=min(mean))

# 6º Selección del mejor modelo
svm_rbf_best <-
  svm_rbf_res %>%
  select_best(metric="accuracy")

svm_rbf_best

```

1.10.9. Comparación

```

models = tibble(model_name =
  ↪ c("lr", "lr_pca", "dt", "rf", "svm_linear", "svm_rbf", "knn"),
              models_tune = list(lr_res, lr_pca_res, dt_res, rf_res2,
  ↪ svm_res, svm_rbf_res, knn_res),
              models_workflow = list(lr_workflow, lr_pca_workflow,
  ↪ dt_workflow, rf_workflow2, svm_workflow,
  ↪ svm_rbf_workflow, knn_workflow))

# save(models, file="salidas_intermedias/all_models.RData")

```

```

load("salidas_intermedias/all_models.RData")
models = models %>%
  mutate(best_tuning = map(models_tune,
                           function(x) select_best(x, metric =
                               ↪ "accuracy")),
         best_metrics = map2(models_tune,
                              best_tuning,
                               ↪ ~ collect_predictions(.x, parameters = .y) %>%
                               ↪ get_metrics() %>%
                               ↪ extract2(1)), # Para extraer solo las medidas y no la matriz de
                               ↪ confusión
         roc = map2(models_tune,
                     best_tuning,
                     ~ collect_predictions(.x, parameters = .y) %>%
                     ↪ roc_curve(fit, .pred_0))
)

# metricas
metrics = models %>%
  select(model_name, best_metrics) %>%
  unnest(best_metrics)
kable(metrics, digits=3)

# curva roc
metrics %>%
  pivot_longer(cols = c(roc_auc, accuracy, recall, specificity,
    ↪ precision),
               names_to = "metric") %>%
  ggplot(aes(x = metric, y = value, group = model_name)) +
  geom_line(aes(col = model_name), size=1) +
  geom_point(aes(col = model_name), size=2.3) +
  scale_color_viridis_d(option="turbo") +
  geom_vline(xintercept=1:5, linetype="dotted") +
  labs(col = "Modelo", title = "Métricas sobre validación") +
  theme_minimal() +
  theme(axis.line.x = element_line(color="black", size = 1),
        axis.line.y = element_line(color="black", size = 1))

# plot medidas
models %>% select(model_name, roc) %>% unnest(roc) %>%
  ggplot(aes(x = 1 - specificity, y = sensitivity, col = model_name)) +
  geom_path(lwd = 1, alpha = 0.7) +
  geom_abline(lty = 3) +
  coord_equal() +
  scale_color_viridis_d(option="turbo") +
  labs(color="Modelo")+
  # scale_color_viridis_d(option = "turbo", name="Modelo") +

```

```
theme_minimal() +
theme(axis.line.x = element_line(color="black", size = 1),
      axis.line.y = element_line(color="black", size = 1))+
ggtitle("Curva ROC en validación")
```

1.10.10. Test

Se unen los conjuntos training y validation para entrenar el modelo final

```
set.seed(345)
models <- models %>%
  mutate(final_workflow = map2(models_workflow, best_tuning,
    ↪ finalize_workflow),
         last_fit = map(final_workflow, function(x)
    ↪ last_fit(x, splits, add_validation_set=T)))

models = models %>%
  mutate(test_metrics = map(last_fit,
    ↪ ~collect_predictions(.x) %>%
    ↪   get_metrics() %>%
    ↪   extract2(1)), # Para extraer solo las
    ↪   medidas
         test_roc = map(last_fit,
    ↪ ~collect_predictions(.x) %>%
    ↪   roc_curve(fit, .pred_0))
    ↪   )

# save(models, file="salidas_intermedias/all_models_test.RData")

# metricas en test
test_metrics = models %>% select(model_name, test_metrics) %>%
  ↪ unnest(test_metrics)
kable(test_metrics, digits=3)

# plot
test_metrics %>%
  pivot_longer(cols = c(roc_auc, accuracy, recall, specificity,
    ↪ precision),
              names_to = "metric") %>%
  ggplot(aes(x = metric, y = value, group = model_name)) +
  geom_line(aes(col = model_name), size=1) +
  geom_point(aes(col = model_name), size=2.3) +
  scale_color_viridis_d(option="turbo") +
  geom_vline(xintercept=1:5, linetype="dotted") +
  labs(col = "Modelo", title = "Métricas sobre test") +
  theme_minimal() +
```

```

theme(axis.line.x = element_line(color="black", size = 1),
      axis.line.y = element_line(color="black", size = 1))

# roc
models %>% select(model_name, test_roc) %>% unnest(test_roc) %>%
  ggplot(aes(x = 1 - specificity, y = sensitivity, col = model_name)) +
  geom_path(lwd = 1, alpha = 0.7) +
  geom_abline(lty = 3) +
  coord_equal() +
  scale_color_viridis_d(option="turbo") +
  labs(color="Modelo")+
  # scale_color_viridis_d(option = "turbo", name="Modelo") +
  theme_minimal() +
  theme(axis.line.x = element_line(color="black", size = 1),
        axis.line.y = element_line(color="black", size = 1))+
  ggtitle("Curva ROC en test")

```

Para calcular la medida de importancia de las variables en bosque aleatorio. No se hace desde el principio para que la computación sea más rápida.

```

# Se hace el last_fit manualmente:
cores = 8

# last model
last_rf_mod <- rand_forest(mtry = rf_best2$mtry, min_n = rf_best1$min_n,
  ↪ trees = 1000) %>%
  set_engine("ranger", num.threads = cores, importance="impurity") %>%
  set_mode("classification")

# last workflow
last_rf_workflow <-
  rf_workflow2 %>%
  update_model(last_rf_mod)

# last fit
set.seed(345)
last_rf_fit <-
  last_rf_workflow %>%
  last_fit(splits,
           add_validation_set = T)

# VIP
last_rf_fit %>%
  extract_fit_parsnip() %>%
  vip(num_features = 50, aesthetics = list(fill="lightblue")) +
  theme_minimal()

```


1.11. Aplicación de los modelos

```
# Librerías -----
# Se cargan las librerías que se usarán en esta sección
library(tidyverse) # Manipulación de datos
library(sf) # Vector data
library(tidymodels) # Ecosistema para la construcción de modelos
library(ggpubr) # Función ggarrange
library(knitr) # Función kable
library(skimr) # Función skim
library(terra)

# Carga de datos -----
load("salidas_intermedias/datos_strat_depurados_geom_2024-04-27.RData")

# Polígono de Andalucía -----
and <- esp_get_ccaa(ccaa = "Andalucía") %>%
  st_transform(st_crs(datos))
```

1.11.1. Visión general del desempeño del modelo

Se construye una rejilla de puntos con una separación de 10km entre ellos (en la dirección Norte-Sur y Este-Oeste). En cada uno de los puntos se predice la probabilidad de incendio el día 15 de cada mes usando los mejores modelos construidos. Para ello, primero hay que asignar a cada punto los valores correspondientes de las variables predictoras consideradas.

```
# grid de puntos 10km x 10km de andalucía
grid = st_make_grid(and,
                    cellsize = c(10000,10000), # 10000
                    what = "centers")[and]

g = and %>%
  ggplot() +
  geom_sf() +
  theme_minimal()

g +
  geom_sf(data = grid,color="red",size=0.6) +
  labs(title = "Malla de puntos con una resolución de 10km x 10km")
```

Se va a analizar cada observación el 15 de cada mes.

```
sample = NULL

for (m in 1:12) {
  if (is.null(sample)){
```

```

    sample <- tibble(date = rep(ymd(paste("2022",m,"15",sep="/")),
                                geometry = grid) %>% st_sf()
  } else
  sample <- sample %>%
    bind_rows(tibble(date = rep(ymd(paste("2022",m,"15",sep="/")),
                                geometry = grid))
  }

```

Se le asocian todas las variables correspondientes a cada observación.

```

source("scripts/strat/fun_asignar_variables.R")
full_grid = asignar_variables(sample)

```

Se imputan los valores faltantes de NDVI asignándoles los del año anterior, ya que faltan los archivos de marzo y diciembre de 2022.

*# La siguiente función lee el archivo con el NDVI correspondiente a un
→ mes y a un año dados (si está disponible)*

```

read_NDVI = function(MM,YYYY) {
  MM = str_pad(as.character(MM),2,"left",pad = "0")
  YY = substr(as.character(YYYY),3,4)
  if (as.numeric(YY)<=06) {
    ruta <-
    → paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIFF/TE
  } else if (as.numeric(YY)<=11) {
    ruta <-
    → paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIF/TE
  } else if (as.numeric(YY)<=21){
    ruta <-
    → paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/TIFF/t
  }else {
    ruta <-
    → paste0("data_raw/vegetacion/",YYYY,"TERMODMEDMNDVI/InfGeografica/InfRaster/COG/te
  }

  if (file.exists(ruta)) {
    NDVI = rast(ruta)
  } else
    NDVI = NA
  return(NDVI)
}

# Los meses para los cuales no está disponible el archivo de NDVI:
year_month_missing_NDVI = c(
"2003-01",

```

```

"2003-04",
"2017-02",
"2018-11",
"2020-11",
"2021-12",
"2022-03",
"2022-12")

# Para cada observación para la que no está disponible el NDVI (porque
→ la información de ese mes no está disponible), se obtiene el
→ correspondiente al mismo mes del año anterior, si este está
→ disponible, si no, el del año posterior:

missing_NDVI = full_grid |>
  filter(is.na(NDVI)) |>
  mutate(year = year(date), month = month(date)) |>
  group_by(year, month) |>
  filter(paste(year, str_pad(as.character(month), 2, "left", pad =
→ "0"), sep = "-") %in% year_month_missing_NDVI) |> # Se filtra
→ porque también hay observaciones que tienen NA en el NDVI no
→ porque no exista el archivo, si no lo mismo que en ocasiones
→ anteriores, porques discrepancias entre los límites de los
→ polígonos
  nest() |>
  mutate(NDVI_rast = map2(month, year-1, read_NDVI), # Se lee primero el
→ del año anterior
        NDVI_rast =
→ ifelse(is.na(unlist(NDVI_rast)), map2(month, year+1, read_NDVI), NDVI_rast),
→ # Si no está disponible, se toma el del año posterior
        NDVI_nuevo = map2(NDVI_rast, data, ~terra::extract(.x, .y)[, 2])) |>
  select(-NDVI_rast) |>
  unnest(c(data, NDVI_nuevo)) |>
  mutate(NDVI = NDVI_nuevo, .keep = "unused")

ind_modificados = is.na(full_grid$NDVI) &
→ (paste(year(full_grid$date), str_pad(as.character(month(full_grid$date)), 2, "left",
→ "0"), sep = "-") %in% year_month_missing_NDVI) # Los elementos que
→ han sido modificados

# Se asignan los valores imputados del NDVI:
full_grid[ind_modificados,]$NDVI = missing_NDVI$NDVI

# Resumen
datos %>% st_drop_geometry %>% skim(.data_name = "datos")

```

Se agrupan los niveles de uso de suelo

```
full_grid <- full_grid |>
  mutate(uso_suelo = fct_other(uso_suelo,
                              keep =
                                ↪ c("21","22","23","24","31","32","33"),
                              other_level= "Otro"))

# save(full_grid,file = full_grid_meses_2022_processed.RData"
```

Se usará el modelo de regresión logística lasso final,

```
load("Private/all_models_test.RData")

model <- models %>% filter(model_name=="lr")
# model <- models %>% filter(model_name=="svm_linear")
# model <- models %>% filter(model_name=="rf")

rm(models) # Es un archivo muy pesado, lo eliminamos de la memoria

# Predicciones
pred_class = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid)
pred_probs = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid,type="prob")
pred = cbind(full_grid,pred_class,pred_probs)

# Se cargan los incendios producidos en el año 2022
incendios22 <-
  ↪ st_read(paste0("./data_raw/incendios_2000-2022/incendios_",2022,".shp"))
  ↪ %>%
  st_transform(st_crs(full_grid)) %>%
  mutate(date=ymd(fecha_inic))
```

Se muestra el gráfico con la estimación de la probabilidad de incendio el día 15 de cada mes en todos los puntos. Se añaden los incendios producidos en cada mes del año 2022

```
# Gráfico predicciones mes + Incendios producidos
ggplot(data = and) +
  geom_sf() +
  geom_sf(data = pred, aes(color=.pred_1,alpha=0.8,size = 1.5) +
  facet_wrap(~month(date,label=TRUE)) +
```

```

scale_color_gradientn(colours = rainbow(5,rev=T),limits=c(0,1)) +
# scale_color_gradient(low="blue", high="red")+
guides(alpha = "none") +
theme_minimal() +
theme(axis.text.x=element_blank(),
      axis.ticks.x=element_blank(),
      axis.text.y=element_blank(),
      axis.ticks.y=element_blank(),
      panel.grid.major = element_blank(),
      panel.grid.minor = element_blank()) +
geom_sf(data = incendios22 %>% st_centroid, color = "black", shape
  ↪ =24, size=1,fill = "red") +
labs(title = "Probabilidad de incendio estimada el día 15 de cada mes
  ↪ de 2022",
      subtitle = paste0("Modelo: ",model$model_name),
      color = "Probalidad\nde incendio\nestimada")

```

1.12. Caso de interés

Se va a usar el modelo para estudiar el incendio del 8 de septiembre de 2021 en Sierra Bermeja por ser de especial relevancia.

```

# Se carga la información del incendio
incendios21 <-
  ↪ st_read(paste0("./data_raw/incendios_2000-2022/incendios_",2021,".shp"))
  ↪ %>%
    st_transform(st_crs(datos)) %>%
    mutate(FECHA_INIC=ymd(FECHA_INIC))

incendio_estudio <- incendios21 %>% filter(month(FECHA_INIC)==9)
rm(incendios21)

# Mapa de Andalucía y de las provincias
and <- esp_get_ccaa(ccaa = "Andalucía") %>% st_transform(st_crs(datos))
prov <- esp_get_prov() %>% filter(nuts2.name=="Andalucía") %>%
  ↪ st_transform(st_crs(datos))

# Gráfico del incendio
g = prov %>%
  ggplot() +
  geom_sf() +
  geom_sf(data = incendio_estudio, color="red",fill=alpha("red",0.2))+
  theme_minimal()+
  theme(axis.text.x=element_blank(),
        axis.ticks.x=element_blank(),
        axis.text.y=element_blank(),

```

```

axis.ticks.y=element_blank(),
panel.grid.major = element_blank(),
panel.grid.minor = element_blank())

# Ampliamos la zona del incendio
bbox = st_buffer(incendio_estudio,dist=10000) %>%
  st_bbox()

g1 = prov %>%
  ggplot() +
  geom_sf() +
  geom_sf(data = incendio_estudio, color="red",fill=alpha("red",0.2))+
  theme_minimal() +
  coord_sf(xlim=c(bbox$xmin,bbox$xmax),ylim=c(bbox$ymin,bbox$ymax))

# Gráfico final
gg <- ggarrange(g,g1)
annotate_figure(gg,
  top = text_grob("Caso de estudio: Incendio de Sierra
    ↪ Bermeja\n8 de septiembre de 2021",size = 14))

```

Se procede de forma similar a la sección anterior. Se crea una rejilla de puntos con una separación de 1km, en la zona que rodea al incendio. En cada punto se predecirá el riesgo de incendio el día de inicio del incendio, 15 y 30 días antes y 15, 30 y 45 días después.

```

# Se crea el grid
grid = st_make_grid(st_buffer(incendio_estudio,dist=10000),
  cellsize = c(1000,1000),
  what = "centers")[and]

# Visualización
g +
  geom_sf(data = grid,size=0.7) +
  coord_sf(xlim=c(bbox$xmin,bbox$xmax),ylim=c(bbox$ymin,bbox$ymax))

# Se le asocian las fechas respectivas
sample = tibble(date =
  ↪ rep(incendio_estudio$FECHA_INIC,length(grid)),geometry = grid) %>% #
  ↪ el día del incendio
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC+15,length(grid)),geometry
    ↪ = grid)) %>% # 15 días después
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC+30,length(grid)),geometry
    ↪ = grid)) %>% # el mes después
  bind_rows(tibble(date =
    ↪ rep(incendio_estudio$FECHA_INIC+45,length(grid)),geometry
    ↪ = grid)) %>% # 45 días después del incendio

```

```

      bind_rows(tibble(date =
        ↪ rep(incendio_estudio$FECHA_INIC-15,length(grid)),
        ↪ geometry = grid)) %>% # 15 días antes
      bind_rows(tibble(date =
        ↪ rep(incendio_estudio$FECHA_INIC-30,length(grid)),geometry
        ↪ = grid)) %>% # el mes antes
st_sf()

```

Se le asocian a cada registro todas las variables predictoras correspondientes.

```

source("scripts/strat/fun_asignar_variables - copia.R")
full_grid <- asignar_variables(sample)

# Se eliminan las observaciones con valores perdidos:
full_grid <- full_grid %>% drop_na()

# Se agrupan los niveles de uso de suelo
full_grid <- full_grid |>
  mutate(uso_suelo = fct_other(uso_suelo,
                              keep =
                                ↪ c("21","22","23","24","31","32","33"),
                              other_level= "0tro"))

full_grid %>% st_drop_geometry() %>% skim()

# save(full_grid,file =
  ↪ "salidas_intermedias/full_grid_incendio_0921_processed.RData")

```

Se usará el modelo de regresión logística lasso final para estimar la probabilidad de incendio en cada punto.

```

load("Private/all_models_test.RData")

model <- models %>% filter(model_name=="lr")
# model <- models %>% filter(model_name=="svm_rbf")
# model <- models %>% filter(model_name=="svm_linear")
# model <- models %>% filter(model_name=="rf")

rm(models) # Es un archivo muy pesado, lo eliminamos de la memoria

# Predicciones
pred_class = model %>%
  pull(last_fit) %>%
  .[[1]] %>%
  extract_workflow() %>%
  predict(new_data = full_grid)

```

```
pred_probs = model %>%  
  pull(last_fit) %>%  
  .[[1]] %>%  
  extract_workflow() %>%  
  predict(new_data = full_grid,type="prob")  
pred = cbind(full_grid,pred_class,pred_probs)
```

Se muestra en un gráfico

```
g <- ggplot(data = and) +  
  geom_sf() +  
  geom_sf(data = pred, aes(color=.pred_1, alpha = .pred_1),size = 1.5) +  
  facet_wrap(~date) +  
  scale_color_gradientn(colours = rainbow(5,rev=T),limits=c(0,1)) +  
  # scale_color_gradient(low="blue", high="red")+  
  labs(title="Incendio de Sierra Bermeja",  
        subtitle = paste0("Model: ",model$model_name)) +  
  guides(alpha = "none") +  
  theme_minimal() +  
  theme(axis.text.x=element_blank(),  
        axis.ticks.x=element_blank(),  
        axis.text.y=element_blank(),  
        axis.ticks.y=element_blank(),  
        panel.grid.major = element_blank(),  
        panel.grid.minor = element_blank()) +  
  geom_sf(data = incendio_estudio, fill="transparent",col="red") +  
  labs(color = "Probabilidad\nestimada de\nincendio") +  
  coord_sf(xlim=c(bbox$xmin,bbox$xmax),ylim=c(bbox$ymin,bbox$ymax))
```

g